无标签跨架构模型选择中的宽度混淆：诊断与子空间校正

Qin Liu　Chen Zhong　Fengshan ZHAO*
南京大学新型软件技术国家重点实验室
中国南京

摘要

在没有目标标签时选择预训练编码器，是迁移学习中的常见预处理步骤。RankMe 是一种广泛使用的无标签分数，但其验证主要局限于同一架构族。本文表明，在比较异构架构时，其有效秩会受到倒数第二层宽度的严重混淆：在各向同性随机特征模型下，RankMe 有效秩按 $\Theta(d)$ 缩放；在实验中，其跨架构排序主要追踪特征宽度，而非迁移质量。我们提出子空间校正排序（Subspace-Corrected Ranking, SCR），将目标谱信息与"同一候选编码器在目标数据和固定参考数据上的特征子空间相对几何"结合。其无超参数成员 $\mathrm{SSR}^{\ddagger}$ 用对数有效秩减去对数子空间对齐度。在 MV、VTAB 和 EX 的 22 个共同支持池–任务单元上，$\mathrm{SSR}^{\ddagger}$ 将平均遗憾从 RankMe 的 0.173 降至 0.069；配对差值为 -0.1043（按目标名称聚类的 95% 置信区间 $[-0.167, -0.040]$，$p = 0.00118$）。$\mathrm{SSR}^{\ddagger}$ 面向跨架构族选择，并非 RankMe 的通用替代品；同一架构族内部仍优先使用 RankMe。五个 MV 任务上的概念验证还表明，$\mathrm{SSR}^{\ddagger}$ →RankMe 两阶段流程可在保持相近遗憾的同时减少前向评估，但这不是一般性的成本保证。

1　引言

迁移学习首先要决定对目标任务微调哪个预训练编码器。当候选模型共享同一架构、仅预训练方案不同时，可以在倒数第二层特征上使用无标签分数进行低成本选择。RankMe [6] 计算特征矩阵的有效秩 $r_{\mathrm{eff}}(H)$，并按 $\log r_{\mathrm{eff}}$ 排序。在其原始验证所采用的同架构场景中，候选模型的特征维度 d 固定，因此宽度不会干扰排序。

实际模型库却包含 ResNet、ViT、ConvNeXt、EfficientNet 等结构完全不同的骨干网络，其倒数第二层维度相差可达一个数量级。我们发现，在这种跨架构场景中，RankMe 会系统性失败：在包含 35 个架构、132 个预训练变体的模型池中，它在所有任务上都选择最宽的变体，且表现差于均匀随机选择。

其机制来自近各向同性条件下 RankMe 的仅目标谱形式。修正后的 Marchenko–Pastur 推导表明，在固定正长宽比下，RankMe 有效秩按 $\Theta(d)$ 缩放，因此 $\log r_{\mathrm{eff}}$ 渐近等于 $\log d$ 加一个仅依赖长宽比的常数。该形式结论只针对 RankMe；"旋转不变"本身不足以推出任意分数都随 d 单调变化。

我们的校正是关系式的，而非仅依赖目标谱。SCR 使用同一候选编码器分别提取目标数据和参考数据的特征，并比较二者的子空间。该分数对共同表示基变换保持不变，但并非仅由目标特征的奇异值谱决定。在完整 VTAB 支持上，SA_k 与参考子空间之外的类均值方差比例高度负相关（$\rho_{\mathrm{Sp}} = -0.959$）。这构成机制层面的经验证据，而非下游准确率的形式保证。

贡献。　（1）我们给出 RankMe 在各向同性随机特征模型下的 $\Theta(d)$ 缩放结论，并在多个异构模型池中验证严重的宽度混淆；（2）提出基于候选模型内部"目标–参考"相对几何的

*通讯作者：Fengshan Zhao，fs.zhao@nju.edu.cn

40th Conference on Neural Information Processing Systems (NeurIPS 2026).

SCR 及其无超参数成员 $\mathrm{SSR}^{\ddagger}$ ；(3) 给出适用范围明确的两阶段流程：跨架构族用 $\mathrm{SSR}^{\ddagger}$ ，族内变体用 RankMe ；(4) 构建四个可复现实验池，共覆盖 52 个任务单元，宽度范围为 $d \in [192, 4096]$。

2 相关工作

RankMe [6] 使用 $p_i = \sigma_i / \sum_j \sigma_j$ 定义有效秩；本文关注超出其原始同架构验证范围的异构模型池。VNE [9] 使用归一化平方奇异值的熵，但本文不把针对 RankMe 的定理推广到 VNE。官方分类版 DiSCO [18] 使用目标真实标签构造类条件量，因此本文将其作为有标签比较方法，而不是零标签基线。LogME、H-score、NCTI、LEEP 等同样需要标签。子空间对齐最初用于无监督域适应 [5]；本文则把它用于度量同一候选编码器在目标数据和固定参考数据上的通用–特定特征结构。

3 实验设置

我们采用四个架构差异显著的模型池，其概况见表 1，各池完整细节见附录 B–E。**MV 池** (多变体池) 包含 132 个 timm [16] 变体、35 个拥有多个变体的架构和 5 个任务；它是唯一在每个架构下包含多个变体的模型池，因此也只有该池用于评估两阶段流程。**VTAB 池** [17] 使用在全部 8 个任务上同时拥有缓存特征与线性探针结果的 24 个架构；共同支持评估中 STL-10 仅作为参考，因此保留 7 个目标任务。**SSL 池**包含 8 个自监督或多模态编码器与 29 个任务，包括 CLIP [13]、DINOv2 [12]、DINO [2] 和 MoCo [8]；它以较少骨干覆盖不同预训练目标。**EX 池**包含来自 35 个规范架构的 51 个监督预训练 timm 变体和 10 个任务，其中包括 $d = 4096$ 的 VGG-16；其宽度跨度与 MV 池相同，均为 21.3×，但覆盖更多任务。四个池合计包含 52 个任务单元，宽度范围为 $d \in [192, 4096]$。

表 1: 四个异构评估池。宽度跨度决定混淆严重程度。

模型池	架构数	变体数	任务数	d 范围	$d_{\max}/d_{\min}$
MV (多变体)	35	119 (多变体) /132 (全部)	5	$[192, 4096]$	21.3×
VTAB	24	24	8	$[192, 2048]$	10.7×
SSL/多模态	8	8	29	$[384, 2048]$	5.3×
EX (监督预训练)	35	51	10	$[192, 4096]$	21.3×

分数。有效秩严格采用 RankMe 定义：$p_i = \sigma_i / \sum_j \sigma_j$ ，$r_{\mathrm{eff}} = \exp(-\sum_i p_i \log p_i)$。对每个候选编码器 m ，SA_k 比较其目标特征与 STL-10 特征；二者由同一编码器产生，因此维度都为 d_m。所有主要结果使用未经额外中心化的特征矩阵，默认 $k = 20$，取对数前将正值下限裁剪为 10^{-12}。不同候选模型的子空间从不直接比较。官方分类版 DiSCO 和其他需要标签的方法与零标签 RankMe–$\mathrm{SSR}^{\ddagger}$ 比较分开报告。

线性探针真值。我们使用单次固定 80/20 划分上、$C = 1$ 的 ℓ_2 正则逻辑回归之留出准确率 (`lp_acc`)。策略质量以相对逐任务 oracle 准确率的差距，即遗憾表示。置信区间由任务级 bootstrap 获得，重采样次数 $n_{\mathrm{boot}} = 10{,}000$；方法间比较采用配对 bootstrap。

4 宽度混淆

引理 1 (Marchenko–Pastur 缩放)**.** 令 $H \in \mathbb{R}^{n \times d}$ 的各行独立同分布于 $\mathcal{N}(0, \sigma^2 I_d)$。当 $n, d \to \infty$ 且 $\gamma = n/d$ 固定时，$r_{\mathrm{eff}}(H)/d \to c(\gamma) > 0$ 几乎处处成立，其中 $c(\gamma)$ 仅依赖长宽比。因此 $r_{\mathrm{eff}}(H) = \Theta(d)$。

命题 2 ($\mathrm{SSR}^{\ddagger}$ 的关系性与共同基不变性)**.** 对候选编码器 m 和 $Q \in O(d_m)$，同时将 $(H_{m,T}, H_{m,R})$ 替换为 $(H_{m,T}Q, H_{m,R}Q)$，其主角、SA_k 和 $\mathrm{SSR}^{\ddagger}$ 均不变。但是，$\mathrm{SSR}^{\ddagger}$ 并非只由 $H_{m,T}$ 的奇异值决定；它还依赖目标与参考右奇异子空间的相对几何。

引理 1 是 RankMe 特有的结论；仅凭旋转不变性不能推出任意分数都关于 d 单调。命题 2 说明，$\mathrm{SSR}^{\ddagger}$ 在不依赖任意共同基选择的同时，引入了目标谱中没有的信息。在 EX 上，

RankMe 与 d 在 10 个任务上的平均 Kendall 相关为 $\tau = +0.617$，进一步确认了强宽度一致性。

跨模型池的经验混淆。RankMe 与宽度的逐任务平均 Spearman 相关在 MV、VTAB、SSL 上分别为 0.61、0.879、0.815；而宽度与线性探针准确率的平均相关分别为 -0.10、$+0.23$、-0.45。因此，宽度可强烈支配 RankMe，却不能可靠识别最佳迁移表示。MV 中 RankMe 在五个任务上均选择 $d = 4096$ 的 VGG-16，平均遗憾 0.319，比随机选择高 0.125。在 VTAB 上，即便宽度–准确率的平均相关为正，RankMe 的平均遗憾 0.110 仍略差于随机选择的 0.106。

表 2: MV、VTAB 与 SSL 模型池中的宽度混淆；EX 诊断见附录 E。RankMe 与 d 高度正相关，但 d 本身不能可靠预测质量。

模型池	架构、任务	$\rho_{\mathrm{Sp}}(\mathrm{RankMe}, d)$	$\rho_{\mathrm{Sp}}(d, \mathrm{lp_acc})$	RankMe 遗憾	随机遗憾
MV	35, 5	$+0.61$	-0.10	$+0.319$	$+0.194$
VTAB	24, 7	$+0.879$	$+0.23$	$+0.110$	$+0.106$
SSL	8, 29	$+0.815$	-0.45	$+0.103$	$+0.066$

VTAB 逐任务结果。表 3 对每个非参考目标均使用同一组 24 个候选。RankMe–宽度相关从 0.838 到 0.915，而遗憾随任务显著变化。

表 3: 完整 24 架构支持上的 VTAB 逐任务宽度混淆。STL-10 因作为参考数据集而排除。

任务	$\rho_{\mathrm{Sp}}(\mathrm{RankMe}, d)$	遗憾	RankMe 选择
CIFAR-10	$+0.865$	$+0.050$	efficientnet_b3 ($d = 1536$)
CIFAR-100	$+0.869$	$+0.235$	efficientnet_b3 ($d = 1536$)
DTD	$+0.877$	$+0.095$	resnet101 ($d = 2048$)
Fashion-MNIST	$+0.886$	$+0.045$	wide_resnet50_2 ($d = 2048$)
Flowers-102	$+0.838$	$+0.165$	efficientnet_b3 ($d = 1536$)
Pets	$+0.902$	$+0.070$	mobilenetv3_large ($d = 1280$)
SVHN	$+0.915$	$+0.110$	efficientnet_b3 ($d = 1536$)
平均	$+\mathbf{0.879}$	$+\mathbf{0.110}$	—

严重程度由架构间宽度方差驱动。MV 池覆盖 $d \in [192, 4096]$，VGG-16 位于高宽度尾部，因此失败最明显。只移除三个 VGG 变体（约占模型池 3%），Flat-RankMe 遗憾便下降 0.175，接近随机策略；而 $\mathrm{SSR}^{\ddagger}$ 的观测遗憾不变。逐任务看，Flat-RankMe 在五个任务上均选中 `vgg16`，$\mathrm{SSR}^{\ddagger}$ 则在 4/5 个任务上选到距离 oracle 不超过 0.07 LP 的候选。

表 4: MV 多变体支持上的逐任务结果。

任务	Oracle	随机	RankMe	$\mathrm{SSR}^{\ddagger}$	RankMe 选择	$\mathrm{SSR}^{\ddagger}$ 选择	Oracle 架构
CIFAR-10	.970	.785	.550	.870	vgg16	resnet50	convnext_base
CIFAR-100	.825	.484	.180	.670	vgg16	resnet152	convnext_base
DTD	.740	.564	.445	.720	vgg16	convnext_base	convnext_base
EuroSAT	.955	.881	.765	.905	vgg16	efficientnet_b3	densenet201
SVHN	.615	.430	.570	.450	vgg16	efficientnet_b3	densenet169

谱截断的独立验证。在每个候选的前 D 个奇异值上重新计算 r_{eff}，可独立检验混淆是否来自奇异值谱尾部。MV 池上取 $D = 256$ 时，$\rho_{\mathrm{Sp}}(r_{\mathrm{eff},D=256}, d)$ 从完整谱的 $+0.63$ 降至 $+0.06$，Flat-RankMe 遗憾由 $+0.319$ 降至 $+0.094$，与 $\mathrm{SSR}^{\ddagger}$ 相当。但谱截断不适用于两阶段流程：ViT-tiny 和 DeiT-tiny 的 $d = 192$，完全不会被截断，因而仍保留宽度次序；其多变体支持上的阶段 1 遗憾为 $+0.204$，超过 $\mathrm{SSR}^{\ddagger}$ 的两倍（附录 E）。

相关的经验失败。在 MV 池上，LogME 和 H-score 的迹形式也在全部任务上选择 `vgg16`，且存在 VGG 时性能下降；LEEP 和 NCTI 不呈现这一模式。这里只报告经验观察：形式化宽度混淆结论仅适用于给定各向同性模型下的 RankMe，不覆盖任意谱分数或旋转不变分数。

表 5: MV 多变体支持上的平坦比较（119 变体 $\times 5$ 任务）。数值为保留或移除三个 VGG 变体时的逐任务平均遗憾。

方法	含 VGG	不含 VGG	Δ	类型
随机	$+0.194$	$+0.193$	-0.001	—
Flat-RankMe	$+0.319$	$+0.144$	-0.175	无标签
Flat-LogME	$+0.319$	$+0.550$	$+0.231$	有标签
Flat-H-score	$+0.319$	$+0.470$	$+0.151$	有标签
Flat-NCTI	$+0.162$	$+0.155$	-0.007	有标签
Flat-SSR‡	$\mathbf{+0.098}$	$\mathbf{+0.098}$	$\mathbf{0.000}$	**无标签**
Flat-LEEP	$+0.038$	$+0.038$	0.000	有标签

表 6: MV 池中平坦策略对 VGG 类 $d = 4096$ 特征的敏感性。数值为五个任务的平均 LP。

方法	含 VGG	不含 VGG	Δ	类型
随机	0.629	0.630	$+0.001$	—
Flat-RankMe	0.502	0.677	$+0.175$	无标签
Flat-NormRankMe ($-\log d$)	0.600	0.449	-0.151	无标签
Flat-SSR‡	$\mathbf{0.723}$	$\mathbf{0.723}$	$\mathbf{0.000}$	无标签
Flat-LogME	0.502	0.271	-0.231	有标签
Flat-H-score	0.502	0.351	-0.151	有标签
Flat-LEEP	0.783	0.783	0.000	有标签
Flat-NCTI	0.659	0.666	$+0.007$	有标签

5 子空间校正排序

几何前提。对候选编码器 m，令 $V_{m,\mathrm{ref},1:k}$ 为其在固定参考数据集上的特征 $H_{m,D_{\mathrm{ref}}}$ 的前 k 个右奇异向量，并记 $P = V_{m,\mathrm{ref},1:k} V_{m,\mathrm{ref},1:k}^{\top}$、$Q = I - P$。定义

$$f_{\mathrm{spe}}(H, H_{\mathrm{ref}}) := \frac{\mathrm{tr}(Q \Sigma_B Q)}{\mathrm{tr}(\Sigma_B)},$$

即位于参考子空间之外的类间协方差比例。f_{spe} 衡量候选模型的判别方差中，有多少是架构特定的，而非与通用编码器共享。在完整 VTAB 支持（$24 \times 7 = 168$ 个架构–任务对）上，SA_k 与 f_{spe} 几乎完全负相关（$\rho_{\mathrm{Sp}} = -0.959$）；逐任务内部，$f_{\mathrm{spe}}$ 对 LP 准确率的平均 Spearman 相关为 $+0.420$。因此，减去子空间对齐度是一种有经验依据的无标签惩罚，用于降低类均值方差被通用子空间吸收的候选得分；这只是机制证据，不是下游保证。由于 `resnet152` 只在八个 VTAB 数据集中的一个同时具备参考和目标特征，我们将其统一排除；最终 24 架构支持上的全部 168 对均成功计算。

对候选编码器 m，令未经额外中心化的特征矩阵为 $H_{m,T} \in \mathbb{R}^{n_T \times d_m}$ 和 $H_{m,R} \in \mathbb{R}^{n_R \times d_m}$。令 $V_T, V_R \in \mathbb{R}^{d_m \times k_m}$ 分别包含其前导右奇异向量，其中 $k_m = \min\{k, n_T, n_R, d_m\}$，默认 $k = 20$。若主角为 $\theta_1, \ldots, \theta_{k_m}$，则

$$\mathrm{SA}_k(H_{m,T}, H_{m,R}) = \frac{1}{k_m} \|V_T^{\top} V_R\|_F^2 = \frac{1}{k_m} \sum_{i=1}^{k_m} \cos^2 \theta_i.$$

完整流程为：使用同一候选编码器提取目标与参考特征；分别计算未经额外中心化的 SVD；保留两个前 k_m 子空间；由主角计算 SA_k；由目标奇异值计算 RankMe 的 r_{eff}；将 r_{eff} 和 SA_k 裁剪到至少 10^{-12}；最后返回标量分数。候选模型的特征维度可以不同，因为不存在跨候选的子空间比较。

SCR 分数族定义为

$$\mathrm{SCR}(H, T; \beta, g) = \frac{\log r_{\mathrm{eff}}(H) + \beta g\big(\mathrm{SA}_k(H, H_{\mathrm{ref}})\big)}{\log C(T)},$$

其中 g 单调递减且 $\beta \geq 0$。取 $g(s) = -\log s$、$\beta = 1$ 得到实际用于全部主结果的分数

$$\boxed{\mathrm{SSR}^{\ddagger}(H, T) = \frac{\log r_{\mathrm{eff}}(H) - \log \mathrm{SA}_k(H, H_{\mathrm{ref}})}{\log C(T)}}.$$

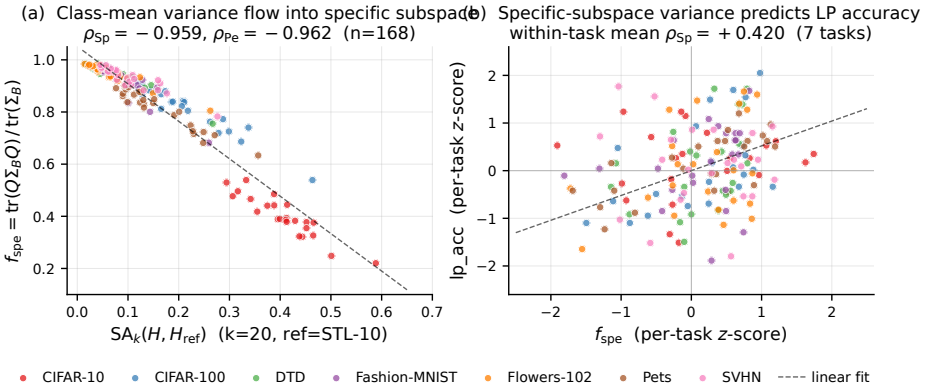


图 1: （a）子空间对齐度 SA_k 与架构特定子空间中的类均值方差比例 f_{spe} 近乎完全负相关；（b）在每个任务内部，f_{spe} 能预测线性探针准确率。

对固定任务，正因子 $1/\log C(T)$ 不改变候选排序。该分数对共同表示基变换不变，但不是目标奇异值谱的单输入函数。

所有主实验使用 STL-10 作为实用而非理论最优的参考数据集：它规模较小、包含多类自然物体、所有候选均支持，并与七个 VTAB 目标任务不重合。我们的默认建议是选用一个通用且与目标不重叠的参考数据集。完整 24 架构 VTAB 支持上，STL-10 单参考的遗憾为 0.061；四个预先指定参考数据集的逐目标留一中位数集成为 0.055。论文早期 Flowers-102 自参考结果因目标/参考泄漏而撤回。集成收益仅基于七个任务，且参考侧成本近似线性增加，因此单参考仍为默认方案。

在 MV 的 5 个任务、VTAB 的 7 个非参考任务以及 EX 的 10 个任务组成的 22 个共同支持池–任务单元上，$\mathrm{SSR}^{\ddagger}$ 的平均遗憾为 0.069，RankMe 为 0.173，随机选择为 0.137。$\mathrm{SSR}^{\ddagger}$ 减 RankMe 的配对差值是 -0.1043（单元 bootstrap 的 95% CI 为 $[-0.169, -0.046]$，$p = 0.00016$）。这些观测包含 10 个不同目标名称，其中 8 个跨模型池重复；按目标名称聚类重采样后，95% CI 为 $[-0.167, -0.040]$，双侧 $p = 0.00118$（100,000 次重采样），配对 Wilcoxon 检验为 $p = 0.00254$。

表 7: 22 个共同支持池–任务单元上的零标签跨池比较。官方分类 DiSCO 使用目标标签，故不列入此表。

方法	平均遗憾	标签预算	作用
随机选择	0.137	零	参照
RankMe	0.173	零	目标谱
$\mathrm{SSR}^{\ddagger}$	**0.069**	零	目标–参考几何

几何机制的验证使用完整 VTAB 支持上的 $24 \times 7 = 168$ 个架构–任务对。SA_k 与参考子空间之外的类间协方差比例 f_{spe} 的相关为 -0.959；逐任务内部，f_{spe} 与线性探针准确率的平均相关为 $+0.420$。这只是经验机制证据，不是 $\mathrm{SSR}^{\ddagger}$ 与下游准确率之间的理论界。

范围。Marchenko–Pastur 引理只刻画给定各向同性模型下的 RankMe；我们不声称 $\mathrm{SSR}^{\ddagger}$ 与线性探针准确率之间存在理论界。几何前提是经验性的，参考选择是启发式的，相对于有标签方法的性能也依赖模型池。本文的具体主张是：在所评估的异构共同支持上，$\mathrm{SSR}^{\ddagger}$ 校正了 RankMe 的跨架构族宽度混淆。

负结果。两种失败模式界定了 $\mathrm{SSR}^{\ddagger}$ 的适用范围。第一，将 TwoNN 内在维度 [4] 纳入 $\log r_{\mathrm{eff}}/(\mathrm{UID} \cdot \log C)$ 并不能改善跨架构排序：MV 多变体支持上的池级平均 $\Delta\rho(\mathrm{SCR}_{\mathrm{uid}} - \mathrm{SSR}^{\ddagger}) = -0.538$（95% CI $[-0.782, -0.270]$），每个架构族分别计算也均为负。内在维度代理不能替代子空间对齐。第二，在候选仅因同一骨干族的预训练方案而异的 ViT-only 子池中，SA_k 轮廓相似且与 LP 准确率不相关；$\mathrm{SSR}^{\ddagger}$ 比 RankMe 低 $\Delta\rho = -0.26$（95% CI $[-0.43, -0.07]$，$p = 0.010$）。这是同族局限，而两阶段流程在架构选择后使用 RankMe，按构造规避了这一问题。

6 两阶段与混合预算流程

算法 1 两阶段无源模型迁移性估计流程

1: **输入：**候选池 $\{(a, V_a)\}$、目标特征 H_T、参考特征 H_{ref}。
2: **阶段 1（架构）：**对每个架构 a 的规范代表 $\bar{v}_a \in V_a$ 计算分数 s_1，并令 $a^* = \arg\max_a s_1(\bar{v}_a, T)$。
3: **阶段 2（变体）：**对 $v \in V_{a^*}$ 计算分数 s_2，返回 $v^* = \arg\max_v s_2(v, T)$。

在五个 MV 任务上，平坦策略平均评估 118.8 个变体；两阶段流程平均评估 $35 + 3 = 38$ 个候选。无标签流程 $\text{SSR}^\ddagger \to$RankMe 的遗憾为 0.102，接近平坦 $\text{SSR}^\ddagger$ 的 0.098，前向评估量约为其三分之一。该结果只应视为五任务概念验证，不构成一般性能或成本保证。探索性的混合预算版本在阶段 1 使用带标签 H-score：$K = 5$ 时遗憾为 0.089，$K = 35$ 时为 0.018。

表 8: MV 多变体池上的流程比较（35 个架构、119 个变体、5 个任务）。成本为每个任务的（变体，任务）特征前向评估次数。

策略	平均 LP	遗憾	95% CI	成本
S1 随机	0.627	+0.194	$[+0.118, +0.289]$	1.0
S2 Flat-RankMe	0.502	+0.319	$[+0.149, +0.509]$	118.8
S3 Flat-$\text{SSR}^\ddagger$	0.723	+0.098	$[+0.048, +0.148]$	118.8
S4 两阶段 RankMe→RankMe	0.677	+0.144	$[+0.093, +0.220]$	38.0
S5 两阶段 $\text{SSR}^\ddagger \to$RankMe（无标签）	**0.719**	**+0.102**	$[+\mathbf{0.044}, +\mathbf{0.153}]$	**38.0**
两阶段 H-score→RankMe（混合，阶段 1 用 $K = 35$ 个标签）	**0.803**	**+0.018**	—	**39.0**

混合预算版本。作为同一组五个 MV 任务上的探索扩展，我们在阶段 1 以 H-score [1] 替代 $\text{SSR}^\ddagger$，只对 K 个架构代表使用标签，并在阶段 2 保留 RankMe。观测遗憾在 $K = 5$ 时为 0.089，在 $K = 35$ 时为 0.018。这些点仅说明该基准上可能存在标签–计算折衷；有限任务数不足以支持一般部署建议。

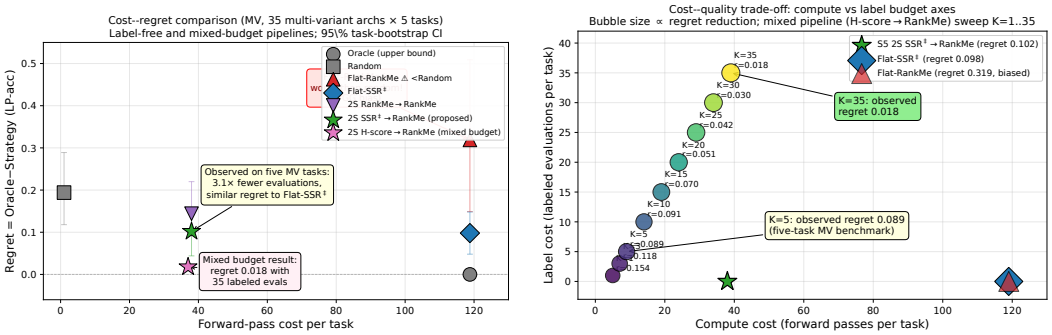


图 2: 五任务 MV 概念验证。左：遗憾与前向评估次数；右：混合流程遗憾与阶段 1 标签预算 K。

7 讨论与局限

$\text{SSR}^\ddagger$ 适用于架构族之间的选择。当候选仅是在同一骨干上的不同预训练方案时，SA_k 变化不足以追踪准确率：ViT-only 子池上 $\text{SSR}^\ddagger$ 相对 RankMe 的 $\Delta\rho = -0.26$（95% CI $[-0.43, -0.07]$，$p = 0.010$）。因此实践规则是：跨架构族使用 $\text{SSR}^\ddagger$；同族变体使用 RankMe；混合多变体模型库采用 $\text{SSR}^\ddagger$ 后接 RankMe。

官方 DiSCO 与 $\text{SSR}^\ddagger$ 的相对表现依赖模型池，尤其在 SSL 和 EX 上。更重要的是，官方分类 DiSCO 使用目标真实标签形成类条件协方差，而 $\text{SSR}^\ddagger$ 不使用目标标签，因此二者不能被表述为同一标签预算下的统一优劣关系。

本研究仍有四项主要局限：参考数据集选择是启发式的；子空间对齐与下游准确率之间没有形式保证；相对有标签方法的性能依赖模型池；两阶段实验仅有五个 MV 任务。本文的严格主张仅是：在所评估的异构共同支持上，$\mathrm{SSR}^{\ddagger}$ 校正了 RankMe 的跨架构族宽度混淆。

8 结论

在异构架构池中，RankMe 会受到特征宽度的严重混淆：在给定各向同性模型下，其有效秩按 $\Theta(d)$ 缩放，因此可能按宽度而非迁移质量排序。$\mathrm{SSR}^{\ddagger}$ 使用同一候选编码器内部的目标–参考子空间关系，补充目标谱所缺少的信息。在 22 个完整共同支持单元上，它将平均遗憾从 0.173 降至 0.069（差值 -0.1043；目标聚类 95% CI $[-0.167, -0.040]$，$p = 0.00118$）。结果支持跨架构族零标签选择使用 $\mathrm{SSR}^{\ddagger}$、同架构族选择使用 RankMe，同时把参考设计、下游保证、模型池依赖性和更广泛的两阶段验证留作未来工作。

Acknowledgments and Disclosure of Funding

本工作得到“111 中心”（编号 B26023）和教育部基础学科与交叉学科突破计划（编号 JYB2025XDXM118）的支持。

参考文献

[1] Yajie Bao, Yang Li, Shao-Lun Huang, Lin Zhang, Lizhong Zheng, Amir Zamir, and Leonidas Guibas. An information-theoretic approach to transferability in task transfer learning. In *IEEE International Conference on Image Processing (ICIP)*, pages 2309–2313, 2019.

[2] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 9650–9660, 2021.

[3] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*, 2021.

[4] Elena Facco, Maria d'Errico, Alex Rodriguez, and Alessandro Laio. Estimating the intrinsic dimension of datasets by a minimal neighborhood information. *Scientific Reports*, 7:12140, 2017.

[5] Basura Fernando, Amaury Habrard, Marc Sebban, and Tinne Tuytelaars. Unsupervised visual domain adaptation using subspace alignment. In *IEEE International Conference on Computer Vision (ICCV)*, pages 2960–2967, 2013.

[6] Quentin Garrido, Randall Balestriero, Laurent Najman, and Yann LeCun. Rankme: Assessing the downstream performance of pretrained self-supervised representations by their rank. In *International Conference on Machine Learning (ICML)*, volume 202 of *Proceedings of Machine Learning Research*, pages 10929–10974, 2023.

[7] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

[8] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 9729–9738, 2020.

[9] Jaeill Kim, Suhyun Kang, Duhun Hwang, Jungwook Shin, and Wonjong Rhee. VNE: An effective method for improving deep representation by manipulating eigenvalue distribution. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023.

[10] Zhuang Liu, Hanzi Mao, Chao-Yuan Wu, Christoph Feichtenhofer, Trevor Darrell, and Saining Xie. A ConvNet for the 2020s. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11976–11986, 2022.

[11] Vladimir A. Marčenko and Leonid A. Pastur. Distribution of eigenvalues for some sets of random matrices. *Mathematics of the USSR-Sbornik*, 1(4):457–483, 1967.

[12] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024.

[13] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 8748–8763, 2021.

[14] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations (ICLR)*, 2015.

[15] Mingxing Tan and Quoc V. Le. EfficientNet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, pages 6105–6114, 2019.

[16] Ross Wightman. PyTorch Image Models, 2019. URL https://github.com/rwightman/pytorch-image-models.

[17] Xiaohua Zhai, Joan Puigcerver, Alexander Kolesnikov, Pierre Ruyssen, Carlos Riquelme, Mario Lucic, Josip Djolonga, Andre Susano Pinto, Maxim Neumann, Alexey Dosovitskiy, Lucas Beyer, Olivier Bachem, Michael Tschannen, Marcin Michalski, Olivier Bousquet, Sylvain Gelly, and Neil Houlsby. A large-scale study of representation learning with the visual task adaptation benchmark. In *arXiv preprint arXiv:1910.04867*, 2019.

[18] Tengxue Zhang, Yang Shu, Xinyang Chen, Yifei Long, Chenjuan Guo, and Bin Yang. Assessing pre-trained models for transfer learning through distribution of spectral components. In *AAAI Conference on Artificial Intelligence*, 2025.

A Marchenko–Pastur 定律与各向同性

引理证明. 写作 $r_{\mathrm{eff}}(H) = \exp(H_{\mathrm{ent}}(\mathbf{p}))$，其中 RankMe 使用 $p_i = \sigma_i / \sum_j \sigma_j$。令 $\lambda_i = \sigma_i^2/(n\sigma^2)$，经验测度包含全部 d 个特征值，包括 $d > n$ 时的零特征值。由 Marchenko–Pastur 定律 [11]，该测度几乎处处收敛到 μ_γ。定义 $S_d = d^{-1}\sum_j \sqrt{\lambda_j}$ 与 $m_{1/2} = \int \sqrt{x}\,\mathrm{d}\mu_\gamma(x)$。公共尺度 $\sigma\sqrt{n}$ 在 RankMe 中抵消，并有有限维恒等式

$$H_{\mathrm{ent}}(\mathbf{p}) = \log d + \log S_d - \frac{1}{2S_d}\frac{1}{d}\sum_i \sqrt{\lambda_i}\log\lambda_i.$$

因此，取 $0\log 0 = 0$，MP 极限给出

$$H_{\mathrm{ent}}(\mathbf{p}) = \log d + \log m_{1/2} - \frac{1}{2m_{1/2}}\int \sqrt{x}\log x\,\mathrm{d}\mu_\gamma(x) + o(1).$$

对任意固定正长宽比，上述矩均有限，包括谱支撑到达零或在零点存在原子的情形。因此 $r_{\mathrm{eff}}(H)/d \to c(\gamma) > 0$，即 $r_{\mathrm{eff}}(H) = \Theta(d)$。 □

近各向同性的经验诊断。 VTAB 上可获得诊断的架构–任务对中，类协方差统计量 $\eta_\Sigma = \mathrm{Var}_c[\mathrm{tr}(\Sigma_c)]/(\mathbb{E}_c[\mathrm{tr}(\Sigma_c)])^2$ 的中位数为 0.022、均值为 0.035，且 93.3% 小于 0.1。这说明

各向同性近似与这些表示具有经验相关性，但不是对 RankMe 排序的界，也不是其他旋转不变分数的定理。

宽度关联的经验结果。图 3 在双对数坐标上给出 MV、VTAB 与 EX 中逐架构平均的 r_{eff} 和 d。MV 和 EX 均使用完整数据集特征，二者的 Spearman 相关分别为 $+0.70$ 和 $+0.86$。VTAB 使用 $n = 1000$ 个下采样特征；当 $d > n$ 时 r_{eff} 被 n 截断，形成较低的数据带，相关为 $+0.41$。这些有限模型池的现象与渐近引理一致，但本身不能证明该引理。

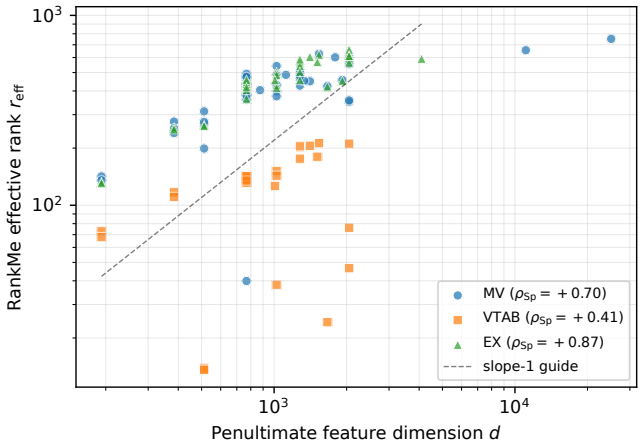


图 3: 各架构跨任务平均后的有效秩与倒数第二层维度（双对数坐标）。三种模型池均呈正向秩相关；斜率为 1 的虚线或点线仅作视觉参考，并非拟合的渐近定律。VTAB 使用 $n = 1000$ 个下采样特征，故 $d > n$ 时 $r_{\text{eff}} \le n$ 形成较低的数据带。

B MV 池（多变体池）

设置。MV 库存包含 132 个 ImageNet-1k 预训练变体；架构选择和两阶段比较使用属于至少含两个变体的 35 个架构族的固定 119 变体支持。所有模型来自 timm [16] 和 torchvision，并在 CIFAR-10、CIFAR-100、DTD、EuroSAT、SVHN 五个目标任务上评估。架构涵盖 VGG [14]、ResNet [7]、DenseNet、EfficientNet [15]、MobileNet、RegNet、ViT [3]、DeiT、ConvNeXt [10]、Swin 等，宽度从 ViT/DeiT-tiny 的 192 到 VGG-16 的 4096，跨度约 21 倍。LP 真值采用与 VTAB 相同的 80/20 划分和 $C = 1$ 的 ℓ_2 正则逻辑回归。

表 9: MV 池的架构族、变体数和倒数第二层维度。

架构族	骨干类别	变体数	d
VGG	CNN	3	4096
ResNet	CNN	8	512, 2048
DenseNet	CNN	4	1024, 2208
EfficientNet	CNN	4	1280–1536
MobileNetV3	CNN	2	960
RegNet	CNN	3	368–1512
ViT	Transformer	6	192, 384, 768
DeiT	Transformer	6	192, 384, 768
ConvNeXt	ConvNet	4	768
Swin Transformer	Transformer	4	768
其他（MnasNet 等）	CNN/混合	5	1280–1984

宽度混淆细节。逐任务 $\rho_{\text{Sp}}(\text{RankMe}, d)$ 范围为 $+0.50$ 至 $+0.72$，均值 $+0.61$，五个任务全部为正。RankMe 在所有任务上均选择 `vgg16`，而 oracle 随任务为 `convnext_base` 或 `densenet201`。RankMe 平均遗憾 $+0.319$，比随机选择的 $+0.194$ 高 0.125。移除三个 VGG 变体（约占模型池 2.3%）后，Flat-RankMe 遗憾降至 $+0.144$；SSR‡ 在移除前后均为 $+0.098$，这里仅将其视为经验稳健性，而非一般不变性。

多变体结构与两阶段评估。该池含 35 个架构族，平均每族 3.8 个变体，范围为 1–8。只有由不少于两个成员的架构族所组成的 119 变体支持能评估两阶段流程：阶段 1 用每个架构的一个规范变体选架构族，阶段 2 在所选族内搜索。相对于平坦评估的 118.8 次前向，记录的平均成本 $35 + 3 = 38$ 对应 3.1 倍前向缩减。

仅 CNN 子池。为排除混淆来自 ViT/CNN 结构差异的解释，我们评估移除 ViT、DeiT 和 Swin 后的 78 个 CNN 类变体。RankMe 在 4/5 个任务上选择 `vgg16`；DTD 上选择宽度次高的 `densenet201`（$d = 2208$）。仅 CNN 子池中的 $\rho_{\mathrm{Sp}}(\mathrm{RankMe}, d) = +0.57$，说明混淆在同一大类架构内仍然存在。

C SSL/多模态池

设置。我们从 8 个 SSL/多模态编码器提取倒数第二层特征：ResNet-50/101、MoCo-v3-R50、ConvNeXt-B、ViT-B/16、CLIP-ViT-L/14、DINOv2-ViT-B/14 和 DINO-ViT-S/16。特征维度 $d \in \{384, 768, 1024, 2048\}$，不含 VGG 类架构。评估使用覆盖 VTAB、MedMNIST 变体和标准迁移基准的 29 个下游任务，LP 真值采用与 MV 相同的 80/20 逻辑回归协议。

宽度混淆。逐任务 $\rho_{\mathrm{Sp}}(\mathrm{RankMe}, d)$ 平均为 $+0.815$，范围 $[+0.45, +0.95]$，其中 27/29 个任务为正。Flat-RankMe 在 25/29 个任务上选择 $d = 2048$ 的 ResNet 类编码器，而 oracle 在 11/29 个任务上为 CLIP-ViT-L/14、在 8/29 个任务上为 ConvNeXt-B。RankMe 平均遗憾为 $+0.103$，随机为 $+0.066$，且 26/29 个任务上非最优。

有标签比较。用官方 PCA-128 DiSCO 替换投稿版代理实现后，在 29 个 SSL 任务上，$G = 6/8$ 的遗憾为 0.045/0.042。被撤回的代理实现为 0.026，官方完整特征评分为 0.057/0.047；它们属于不同算法或维度设置，而非同一协议的重复运行。早期回复草稿中的 0.077/0.071 不对应任何保留输出，是转录错误。由于官方分类 DiSCO 使用目标真实标签形成类条件协方差，我们将其与零标签 $\mathrm{SSR}^{\ddagger}$–RankMe 比较分开，并不主张统一优越性。

表 10: 各模型池上的官方 PCA-128 分类 DiSCO。G 是连续、近等大小谱分组的数量；DiSCO 使用目标标签。

模型池	任务数	$G = 6$ 遗憾	$G = 8$ 遗憾
MV	5	0.146	0.146
VTAB（排除 STL-10）	7	0.067	0.040
EX	10	0.045	0.049
SSL	29	0.045	0.042

D VTAB 池

设置。最终共同模型池包含在八个 VTAB 数据集（CIFAR-10/100、DTD、Fashion-MNIST、Flowers-102、Pets、STL-10、SVHN）上同时拥有完整特征和 LP 值的 24 个 timm 预训练架构。原始清单还列出 ResNet-152，但其八个特征文件只有一个可用，因此我们统一排除，而不让候选集随任务变化。STL-10 特征只作为 SA_k 的参考，并从共同支持目标中排除。

参考任务与 k 消融。审计后的协议采用未经额外中心化的 SVD 和 RankMe 的奇异值归一化，并排除 STL-10 目标。$k = 20$ 时，以 STL-10 为单参考，在完整 24 架构支持的其余七个任务上遗憾为 0.061。投稿版 Flowers-102 自参考结果因参考与目标重合而撤回。早期消融显示稳定区间约为 $k \in [10, 50]$；我们不利用目标标签调参，直接采用中点 $k = 20$。

多参考稳健性。为实现目标不重叠的评估，当当前目标与参考名称相同，就从预先确定的 STL-10、CIFAR-10、Flowers-102、Pets 集合中删去该参考，并对其余对齐度取中位数。该逐目标留一集成遗憾为 0.055，单独使用 STL-10 为 0.061。七个任务上的有限差异不足以抵消约 M 倍的参考侧成本，因此默认仍为一个通用且与目标不重叠的参考，参考设计仍是开放问题。

E EX 池与阶段 1 比较

EX 池。EX 包含来自 35 个规范架构的 51 个 ImageNet-1k 监督预训练变体，其中包括 $d = 4096$ 的 VGG-16，$d_{\max}/d_{\min} = 21.3$。十个目标涵盖细粒度识别（FGVC-Aircraft、Flowers-102、Food-101、Oxford-Pets）、纹理/场景（DTD、EuroSAT）、数字/服饰（SVHN、Fashion-MNIST）和通用物体（CIFAR-10/100），特征在完整数据集上提取。Flat-SSR‡ 遗憾为 $+0.060$，RankMe 为 $+0.144$。依赖目标标签的官方 DiSCO 在 $G = 6/8$ 时为 $+0.045/+0.049$，不纳入零标签比较。

表 11: MV 池平坦比较的复现（与正文表 5 数据相同）。

方法	含 VGG（遗憾）	不含 VGG（遗憾）	类型
随机	$+0.194$	$+0.193$	—
Flat-RankMe	$+0.319$	$+0.144$	无标签
Flat-LogME	$+0.319$	$+0.550$	有标签
Flat-H-score	$+0.319$	$+0.470$	有标签
Flat-NCTI	$+0.162$	$+0.155$	有标签
Flat-SSR‡	$+\mathbf{0.098}$	$+\mathbf{0.098}$	**无标签**
Flat-LEEP	$+0.038$	$+0.038$	有标签

谱截断。在前 D 个奇异值上重新计算 r_{eff} 是有用的诊断：MV 中 $D = 256$ 时，宽度相关下降，平坦遗憾接近 SSR‡。我们不把它作为阶段 1 替代方案，因为 $d < D$ 的候选不会被截断，而且截止值本身引入了额外设计选择。

F 消融与负结果

撤回的探索规则。我们不保留早期用 $d_{\max}/d_{\min}$ 阈值在 SSR‡ 与 DiSCO 间选择的规则：后者依赖标签，而且表面上的交叉点来自已被替代的代理实现。我们也删除加性 SCR 变体的跨池调参主张，因为无超参数主结果并不需要这些主张。

校正的代数形式。MV 池上的 $-\alpha \log \mathrm{SA}_k$ 族中，$\alpha \in [0.5, 2]$ 的遗憾均较相近，为 $+0.093$ 至 $+0.162$；反向控制 $-\log(1 - \mathrm{SA}_k)$ 的遗憾为 $+0.366$，说明减去对齐度的方向很重要。为简洁起见采用 $\alpha = 1$。

MV 池 Flat-RankMe 逐任务结果。Flat-RankMe 在每个任务上都选择 `vgg16`，其 $d = 4096$ 倒数第二层不随目标变化地支配 r_{eff}；Flat-SSR‡ 则选择适合任务的 ConvNeXt、ResNet 或 EfficientNet 变体。

任务	Oracle	随机	Flat-RM	Flat-SSR‡	RM 选择	SSR‡ 选择	Oracle 架构
CIFAR-10	0.970	0.785	0.550	0.870	vgg16	resnet50	convnext_base
CIFAR-100	0.825	0.484	0.180	0.670	vgg16	resnet152	convnext_base
DTD	0.740	0.564	0.445	0.720	vgg16	convnext_base	convnext_base
EuroSAT	0.955	0.881	0.765	0.905	vgg16	efficientnet_b3	densenet201
SVHN	0.615	0.430	0.570	0.450	vgg16	efficientnet_b3	densenet169

负结果 1：UID 损害同族变体排序。在分母中加入 TwoNN 内在维度（$\mathrm{SCR}_{\text{uid}} = \log r_{\text{eff}}/(\mathrm{UID} \cdot \log C)$）不能改善变体排序。MV 多变体支持上的池级平均 $\Delta\rho(\mathrm{SCR}_{\text{uid}} - \mathrm{SSR}^{\ddagger}) = -0.538$（95% CI $[-0.782, -0.270]$），逐架构族结果也全部为负。

负结果 2：SSR‡ 在仅 ViT 子池中退化。当候选限制为 ViT 族架构（ViT、DeiT 和 Swin 变体，共 33 个模型 $\times 10$ 个任务）时，不同预训练方案的 SA_k 轮廓相似但与 LP 准确率无关；SSR‡ 比 RankMe 低 $\Delta\rho = -0.26$（95% CI $[-0.43, -0.07]$，$p = 0.010$，任务配对 bootstrap）。在同时含 ViT 与 CNN 的混合池中，SSR‡ 能识别更好的架构。

同族排序与 $\log C$ 缩放器。在任一单独架构族内，SSR‡ 相比 RankMe 不提供额外排序信号（MV 六个架构族上的 $\Delta\rho \in [-0.48, -0.07]$）。$\log C$ 任务缩放器方便但并非原则性选择：oracle 缩放器 $1/(1 - \overline{\mathrm{LP}})$ 的 Spearman $\rho = +0.82$，SSR‡ 为 $+0.49$，随机逐任务缩放器为 $+0.39$。我们保留 $\log C$ 用于跨任务聚合，同时指出其他逐任务缩放器可能同样可行。

G 实验环境与计算资源核算

加速特征提取。为修正后的 DiSCO 评估补跑 MV 和 EX 特征提取时，使用华为昇腾 NPU，通过 PyTorch 的 `torch_npu` 扩展及 Ascend 工具链运行。留存的启动脚本把候选模型划分为四个独立分片，分配到编号 0–3 的四个 NPU 设备，每个设备运行一个提取进程，配置批大小为 64。模型在推理模式下运行，特征以 float32 数组缓存。这一说明对应有记录的补跑配置，并不意味着全部历史特征缓存都在同一硬件上生成。仓库还保留了建议至少 16 GB 加速器内存的 CUDA 复现指南。

缓存特征分析。修正后的 DiSCO 评分、VTAB 线性探测补齐、参考子空间审计及 bootstrap 分析使用缓存特征，通过 NumPy、SciPy 和 scikit-learn 等基于 CPU 的 Python 例程完成。留存的 MV/EX DiSCO 评分脚本配置了 16 个工作进程。特征缓存将编码器推理与后续评分分离，使重复评估指标时无需重新提取特征。

报告范围。第 6 节的成本比较统计候选模型–任务的前向评估次数，并非实测运行时间加速比、节能比例或 NPU 与 GPU 的硬件对比。参考特征提取及缓存另有初始化成本。历史运行未一致保留加速器具体型号与内存、主机 CPU 与内存、软件版本快照，以及完整的逐次运行时间。因此，本文报告有记录的配置，不声称提供完整的项目级计算预算，并在计算资源 checklist 项中保留“否”的回答。

NeurIPS 论文核查表

1. **论断**

   问题：摘要和引言中的主要论断是否准确反映论文贡献与范围？

   回答：[Yes]

   说明：摘要及第 1、7 节明确陈述了 RankMe 特有的宽度混淆、SSR‡ 的跨架构族范围、修正后的 22 单元结果和主要局限。五任务两阶段结果被明确限定为概念验证，而非一般保证。

2. **局限**

   问题：论文是否讨论了本工作的局限？

   回答：[Yes]

   说明：第 7 节讨论了启发式参考选择、依赖模型池的性能、缺少形式化下游准确率保证、同族退化，以及两阶段流程只有五个任务的有限证据。

3. **理论假设与证明**

   问题：每项理论结果是否给出完整假设与完整、正确的证明？

   回答：[Yes]

   说明：第 4 节给出 RankMe 结论所需的各向同性随机特征和长宽比假设，附录 A 使用 RankMe 的奇异值归一化给出 Marchenko–Pastur 推导。形式结论没有推广到任意旋转不变分数。

4. **实验结果可复现性**

   问题：论文是否充分披露复现主要实验结果及其结论所需的信息，无论是否提供代码和数据？

   回答：[Yes]

   说明：第 5 节给出有效秩、子空间对齐和 SSR‡ 的精确定义与完整算法，包括未经额外中心化的 SVD、$k = 20$ 和数值裁剪。第 3 节及附录 B–E 记录候选池、目标任务、线性探针协议、共同支持和基线口径。

5. **数据和代码的开放获取**

   问题：论文是否开放数据和代码，并提供足以忠实复现主要结果的说明？

   回答：[Yes]

   说明：配套仓库 https://anonymous.4open.science/r/crossarchitecturetransferability-FEC8 提供评分与分析代码、缓存结果表、验证脚本和特征提取说明。

6. **实验设置与细节**

   问题：论文是否说明理解结果所需的全部训练和测试细节？

   回答：[Yes]

   说明：第 3 节和附录 B–E 报告模型池、数据集、特征维度、80/20 线性探针划分、逻辑回归设置、采样约定、参考数据集、k、DiSCO 分组和 bootstrap 流程。本工作不训练预训练编码器。

7. **实验统计显著性**

   问题：论文是否恰当定义并报告误差条或其他统计显著性信息？

   回答：[Yes]

   说明：第 5 节的 22 单元主比较报告单元配对 bootstrap、按目标名称聚类的 95% 置信区间与双侧检验；聚类分析使用 100,000 次重采样，并由配对 Wilcoxon 检验佐证。第 6 节报告五任务两阶段区间及其有限证据范围。

8. **实验计算资源**

   问题：论文是否为每项实验提供充分的计算资源、内存和运行时间信息？

   回答：[No]

说明：附录 G 描述了华为昇腾 NPU 特征提取补跑、四设备分片配置及基于 CPU 的缓存特征分析。历史运行未一致保留精确硬件规格、软件版本快照和完整的逐次运行时间，因此现有信息仍不足以构成完整的计算资源报告。前向评估次数与实测运行时间加速比已作区分。

9. **伦理规范**

   问题：研究是否在各方面符合 NeurIPS 伦理规范 https://neurips.cc/public/EthicsGuidelines？

   回答：[Yes]

   说明：本工作在既有图像分类基准上评估预训练编码器并提出模型选择分数，不涉及人类受试者、私有数据或部署干预；作者已核查 NeurIPS 伦理规范。

10. **更广泛影响**

    问题：论文是否讨论工作的潜在正面与负面社会影响？

    回答：[N/A]

    说明：这是选择既有预训练编码器的基础方法，可能减少不必要的模型评估；除底层预训练模型和基准数据本身的影响外，它不引入直接、特定于应用的社会影响。

11. **安全保障**

    问题：对于具有高误用风险的数据或模型，论文是否说明了负责任发布所采用的保障措施？

    回答：[N/A]

    说明：发布内容是评分与分析代码及数值结果表；没有发布新的预训练模型、抓取数据集、生成系统或其他高风险资产。

12. **既有资产的许可**

    问题：论文是否适当标注所用代码、数据和模型的创作者，并明确说明和遵守许可及使用条款？

    回答：[No]

    说明：所有模型库和基准数据集均引用原始来源，仓库记录了库许可证；论文未逐一列出每个基准数据集的明确许可证，因此不声称许可文档完整。

13. **新资产**

    问题：论文引入的新资产是否有完善文档，并随资产一同提供？

    回答：[No]

    说明：评分代码、结果表、验证脚本和特征提取说明均在仓库中记录，但当前发布版本没有单独的软件许可证文件。

14. **众包与人类受试者研究**

    问题：若涉及众包或人类受试者，论文是否提供参与者说明全文、截图和报酬细节？

    回答：[N/A]

    说明：本研究未进行众包，也不涉及人类受试者。

15. **机构审查委员会批准**

    问题：论文是否说明参与者风险、风险告知和 IRB 或所在国家/机构的等价审批？

    回答：[N/A]

    说明：本研究不涉及人类受试者或研究参与者，因此 IRB 批准与参与者风险披露不适用。

16. **LLM 使用声明**

    问题：如果 LLM 是核心方法中重要、原创或非标准的组成部分，论文是否说明其使用？

    回答：[N/A]

    说明：LLM 仅用于语言编辑，不参与所提方法、实验设计、数据分析或评估流程。