无标签跨架构模型选择中的宽度混淆：诊断与子空间校正

Qin Liu　Chen Zhong　Fengshan Zhao*
南京大学新型软件技术国家重点实验室
中国南京

摘要

在没有目标标签时如何选择预训练编码器，是迁移学习中的一个实际问题。RankMe 主要在同架构族内得到验证；当候选架构不同时，其分数可能受到特征宽度混淆。在固定长宽比的各向同性随机特征模型下，其有效秩按 $\Theta(d)$ 缩放。我们提出子空间校正排序（SCR），在目标谱之外，引入同一候选编码器提取的目标特征与参考特征之间的子空间对齐度。默认成员 $\mathrm{SSR}^{\ddagger}$ 用对数有效秩减去对数子空间对齐度。在三个异构模型池（MV/VTAB/EX）的 22 个池–任务单元上，$\mathrm{SSR}^{\ddagger}$ 相比 RankMe 将平均选择遗憾从 0.133 降至 0.069（配对差值：-0.0645；按目标名称聚类的 95% CI：$[-0.122, -0.020]$）。在 MV 上，平均分数–宽度相关从 0.609 降至 0.305，表明宽度依赖有所减弱，但仍然存在。在五个 MV 任务上，先用 $\mathrm{SSR}^{\ddagger}$ 选择架构、再用 RankMe 选择族内变体的两阶段流程，以更少的候选评估取得与对全部候选使用 $\mathrm{SSR}^{\ddagger}$ 相近的选择遗憾。

1　引言

迁移学习首先要决定将哪个预训练编码器迁移到目标任务。当候选模型共享同一架构、仅预训练方案不同时，可以在倒数第二层特征上使用无标签分数进行低成本选择。RankMe [13] 计算特征矩阵的有效秩 $r_{\mathrm{eff}}(H)$，并按 $\log r_{\mathrm{eff}}$ 排序。在其原始验证所采用的同架构场景中，候选模型的特征维度 d 固定，因此宽度不会干扰排序。

timm [40] 和 torchvision 模型库包含 ResNet [14]、ViT [10]、ConvNeXt [24]、EfficientNet [38] 等特征宽度差异显著的异构骨干。RankMe 的同族验证不足以证明其跨架构可靠性。在包含 119 个候选的多变体（MV）模型池上，RankMe 与宽度明显相关（逐任务平均相关 0.609），其遗憾 0.144 低于随机的 0.191，但高于本文关系型分数 $\mathrm{SSR}^{\ddagger}$ 的 0.098（第 5 节）。在视觉任务适应基准（VTAB）及扩展（EX）模型池上，RankMe 的平均遗憾高于随机。综合这些结果，宽度关联本身并不能决定模型选择表现优于还是劣于随机选择。

其机制来自各向同性条件下 RankMe 的仅目标谱形式。Marchenko–Pastur 推导表明，在固定正长宽比下，RankMe 有效秩按 $\Theta(d)$ 缩放，因此 $\log r_{\mathrm{eff}}$ 渐近等于 $\log d$ 加一个仅依赖长宽比的常数。该形式结论只针对 RankMe；“旋转不变”本身不足以推出任意分数都随 d 单调变化。

图 1 概括了本文思路。给定无标签目标图像和固定、与目标分离的参考数据集，每个候选编码器分别将两组数据映射到自身特征空间。SCR 在目标谱之外引入这两个子空间的相对几何；其默认成员 $\mathrm{SSR}^{\ddagger}$ 用对数有效秩减去对数对齐度。不同编码器之间只比较最终标量分数，因此其特征维度无须相同。这为有标签下游评估之前的预训练骨干筛选提供了无标签方法。在 MV、VTAB 和 EX 的 22 个共同支持池–任务单元上，$\mathrm{SSR}^{\ddagger}$ 将平均选择遗憾从 RankMe 的 0.133 降至 0.069，表明目标–参考子空间几何能够在这些模型池上改善仅依赖目标谱的模型选择。

*通讯作者：Fengshan Zhao，fs.zhao@nju.edu.cn

40th Conference on Neural Information Processing Systems (NeurIPS 2026).

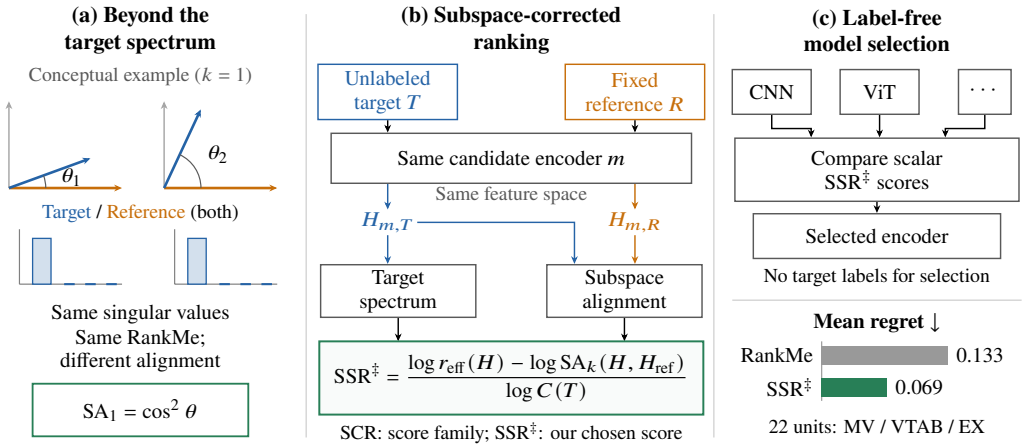


图 1: 子空间校正总览。(a) 相同目标谱可以对应不同的参考相对夹角，但不表示准确率排序。(b) 用同一候选的两组特征计算对齐度，其中 $H = H_{m,T}$、$H_{\text{ref}} = H_{m,R}$。类别数元数据 $C(T) > 1$ 仅统一缩放任务内分数，省略该因子不改变排序。(c) 以标量分数进行零目标标签选择。柱形图汇总 22 个共同支持单元 (表 9)；目标标签仅用于评估。

贡献。 **(1) 问题诊断。**揭示 RankMe 在异构架构之间的特征宽度混淆，并在各向同性随机特征模型下解释其有效秩的缩放规律。**(2) 子空间校正。**提出无标签关系型分数族 SCR，以同一编码器内部的目标–参考几何补充目标谱信息。其默认成员 $SSR^{\ddagger}$ 在所评估的共同支持集上降低了相对 RankMe 的平均选择遗憾。**(3) 预算约束下的选择。**评估以 $SSR^{\ddagger}$ 选择架构、以 RankMe 选择族内变体的两阶段流程，在五个 MV 任务上以更少的候选评估取得与单阶段 $SSR^{\ddagger}$ 相近的遗憾。

2 相关工作

RankMe [13] 使用 $p_i = \sigma_i / \sum_j \sigma_j$ 定义有效秩；本文关注超出其原始同架构验证范围的异构模型池。VNE [20] 使用归一化平方奇异值的熵，但本文不把针对 RankMe 的定理推广到 VNE。官方分类版 DiSCO [45] 使用目标真实标签构造类条件量，因此本文将其作为有标签比较方法，而不是零标签基线。LogME、H-score、NCTI、LEEP 等同样需要标签。子空间对齐最初用于无监督域适应 [12]；本文则把它用于度量同一候选编码器在目标数据和固定参考数据上的通用–特定特征结构。

3 实验设置

表 1 概括四个模型池 (细节见附录 B–E)。MV 包含 48 组中的 132 个 timm/torchvision [40] 变体；其中 35 个多变体组的 119 个变体构成五任务主比较及两阶段支持。VTAB [44] 有 24 个架构在八任务上具备完整特征及 LP 值；排除 STL-10 参考后为七个目标。SSL 包含八个自监督/多模态编码器，包括 CLIP [33]、DINOv2 [31]、DINO [5] 和 MoCo [15]，在 29 个任务上的支持不完整。EX 包含 35 个架构的 51 个监督预训练 timm 变体和十个任务。四个模型清单合计覆盖 52 个任务单元，宽度为 $d \in [192, 4096]$。

表 1: 四个异构评估池。宽度范围描述候选池，不是经过验证的分数选择阈值。

模型池	架构数	变体数	任务数	d 范围	$d_{\max}/d_{\min}$
MV (多变体)	35/48 (全)	119 (多变体) /132 (全部)	5	[192, 4096]	21.3×
VTAB	24	24	8	[192, 2048]	10.7×
SSL/多模态	8	8	29	[384, 2048]	5.3×
EX (监督预训练)	35	51	10	[192, 4096]	21.3×

分数。有效秩严格采用 RankMe 定义：$p_i = \sigma_i / \sum_j \sigma_j$，$r_{\text{eff}} = \exp(-\sum_i p_i \log p_i)$。在 22 单元主比较中，对每个候选编码器 m，SA_k 比较其目标特征与 STL-10 特征；二者由同一编码器产生，因此维度都为 d_m。所有主要结果使用未经额外中心化的特征矩阵，默认 $k = 20$，取对数前将正值下限裁剪为 10^{-12}。不同候选模型的子空间从不直接比较。官方分类版 DiSCO 和其他需要标签的方法与零标签 RankMe–$\text{SSR}^{\ddagger}$ 比较分开报告。

线性探针真值。使用 80/20 划分上 $C = 1$ 的 ℓ_2 正则逻辑回归留出准确率。遗憾是与同一候选集内逐任务 oracle 的差距。22 单元的配对及目标聚类 bootstrap，以及五任务流程区间，均采用 seed=42、100,000 次重采样。

特征提取与预处理。两个 torchvision VGG 模型保留 4096 维隐藏全连接表示，主结果使用一次官方权重预处理。MV 主支持另外保留 23 个非 VGG torchvision 变体，其中包括 SVHN oracle DenseNet-169；其历史提取脚本在 loader 的缩放与归一化之后再次调用官方权重变换。部分历史缓存的逐文件来源不完整，故这说明脚本层面的协议差异，并不等同于逐文件来源均已确认。VGG 同时评估一次变换和匹配历史双重变换的对照；两者给出相同的 22 单元 RankMe/$\text{SSR}^{\ddagger}$ 遗憾，但不能据此认定整个模型池已采用统一预处理（附录 B、G）。

4 宽度混淆

引理 1 (Marchenko–Pastur 缩放)**.** 令 $H \in \mathbb{R}^{n \times d}$ 的各行独立同分布于 $\mathcal{N}(0, \sigma^2 I_d)$，其中 $\sigma > 0$。当 $n, d \to \infty$ 且 $\gamma = n/d \in (0, \infty)$ 固定时，$r_{\text{eff}}(H)/d \to c(\gamma) > 0$ 几乎处处成立，其中 $c(\gamma)$ 仅依赖长宽比。因此 $r_{\text{eff}}(H) = \Theta(d)$。

宽度为何进入分数。令 $\lambda_i = \sigma_i^2/(n\sigma^2)$ 包含全部 d 个特征值，记 $S_d = d^{-1} \sum_i \sqrt{\lambda_i}$。RankMe 的奇异值归一化给出精确恒等式

$$\log r_{\text{eff}}(H) = \log d + \log S_d - \frac{1}{2 S_d d} \sum_i \sqrt{\lambda_i} \log \lambda_i.$$

在给定高斯模型和固定长宽比下，最后两项收敛至有限常数。连续延拓 $\sqrt{x} \log x \to 0$（$x \downarrow 0$）处理零特征值，不要求谱与零点之间存在间隙。因此，宽度通过显式的 $\log d$ 项进入分数。这是解释性模型，并非声称所有预训练表示都各向同性；各类总方差相等也不能证明方向各向同性。完整推导见附录 A。

命题 2 ($\text{SSR}^{\ddagger}$ 的关系性与共同基不变性)**.** 对候选编码器 m，假定保留的右奇异子空间唯一确定，或在奇异值并列时对所选子空间作一致变换。对 $Q \in O(d_m)$，同时将 $(H_{m,T}, H_{m,R})$ 替换为 $(H_{m,T}Q, H_{m,R}Q)$，其主角、SA_k 和 $\text{SSR}^{\ddagger}$ 均不变。一般而言，$\text{SSR}^{\ddagger}$ 并非只由 $H_{m,T}$ 的奇异值决定；它还依赖目标与参考右奇异子空间的相对几何。

校正为何增加信息。共同基变换给出 $V_T' = Q^\top V_T$、$V_R' = Q^\top V_R$，因此 $(V_T')^\top V_R' = V_T^\top V_R$。相反，图 1（a）固定秩一参考，在保持奇异值不变时旋转秩一目标。仅保留一个方向（$k = 1$）时，对齐度为 $\cos^2\theta$：RankMe 无法区分这两个目标，而 $\text{SSR}^{\ddagger}$ 可以。这说明校正引入了目标谱之外的信息，而不是给出了二者下游准确率的排序。

有限模型池示例。图 2 统一使用与主分数一致的 RankMe 奇异值归一化。按架构组取平均后，有效秩与宽度的 Spearman 相关在 VTAB 为 $+0.877$，EX 为 $+0.871$。它们不同于逐任务相关，也不是拟合的渐近定律。

跨模型池的经验关联。MV、VTAB、EX 中，逐任务平均 $\rho_{\text{Sp}}(\text{RankMe}, d)$ 为 0.609、0.879、0.766，宽度–LP 相关为 -0.049、$+0.233$、-0.070。MV 上，$\text{SSR}^{\ddagger}$ 将宽度相关从 0.609 降至 0.305（逐任务范围 $[0.156, 0.495]$），并将分数–LP 相关从 0.352 提高至 0.512。这为降低而非消除宽度依赖提供描述性证据，不证明因果关系。MV RankMe 优于随机；VTAB、EX 的平均遗憾高于各自随机基线（表 2）。EX 中，RankMe 与 d 在 10 个任务上的平均 Kendall 相关为 $\tau = +0.618$。

VTAB 逐任务结果。表 3 对每个非参考目标均使用同一组 24 个候选。RankMe–宽度相关从 0.838 到 0.915，而遗憾随任务显著变化。

VGG 敏感性与任务差异。移除三个 VGG 变体（$3/119 \approx 2.5\%$）不改变 RankMe 和 $\text{SSR}^{\ddagger}$ 的遗憾，仍为 0.144 和 0.098。RankMe 在四个任务上选择 ResNeXt，在 SVHN 选择 Inception。$\text{SSR}^{\ddagger}$ 在四个任务上优于 RankMe，但在 SVHN 更差；距离 oracle 不超过 0.07 LP 的任务只有两个（表 4）。

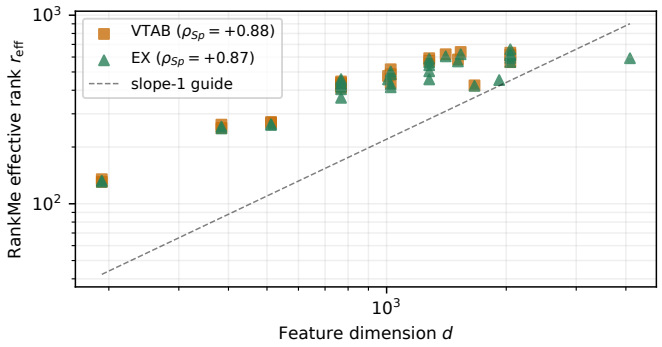


图 2: 24 个 VTAB 与 35 个 EX 架构组的有效秩与特征宽度。斜率为 1 的虚线仅为视觉参考，并非拟合。此谱诊断使用 VTAB 的八个缓存数据集；所有目标选择比较均排除 STL-10。

表 2: 各池的宽度与质量诊断。MV 为 119 个候选；VTAB 排除 STL-10。相关为逐任务 Spearman 的均值。

池	架构/任务	$\rho(\text{RankMe}, d)$	$\rho(d, \text{LP})$	RM 遗憾	随机遗憾
MV	35/5	0.609	−0.049	0.144	0.191
VTAB	24/7	0.879	0.233	0.110	0.106
EX	35/10	0.766	−0.070	0.144	0.131

谱截断诊断。一个 CIFAR-10 单元缺少截断及辅助分数；仅对这类比较，在全部五任务统一剔除该变体，得到完整 118 候选支持。截断 $D = 128/256/512/768$ 的遗憾分别为 0.134/0.134/0.151/0.142，完整谱 RankMe 为 0.144，$\text{SSR}^{\ddagger}$ 为 0.098。部分截止维度改善了 RankMe，但四种设置的遗憾均高于 $\text{SSR}^{\ddagger}$。截止维度也是额外的设计选择（附录 E）。

辅助方法比较。表 5 报告遗憾，表 6 报告平均 LP 准确率，均采用完整 118 候选支持，移除 VGG 后为 115 候选。移除 VGG 会降低 LogME 的准确率，H-score 则不变。朴素宽度归一化 $\log r_{\text{eff}} - \log d$ 的遗憾为 0.200，高于同一 118 候选支持的随机值 0.192；直接扣除宽度在该设置中不足以达到 $\text{SSR}^{\ddagger}$ 的表现。LEEP 列为保留的聚类代理，并非官方 LEEP 实现。这些辅助比较不扩展只针对 RankMe 的理论结论。

5 子空间校正排序

几何前提。对候选编码器 m，将目标和固定参考特征矩阵简记为 $H = H_{m,T}$、$H_{\text{ref}} = H_{m,R}$。令 $V_{m,\text{ref},1:k}$ 包含 H_{ref} 的前 k 个右奇异向量，并记 $P = V_{m,\text{ref},1:k} V_{m,\text{ref},1:k}^{\top}$、$Q = I - P$。令 Σ_B 为按类别频率加权的目标类均值协方差，仅在此诊断中使用目标标签计算。定义

$$f_{\text{spe}}(H, H_{\text{ref}}) := \frac{\text{tr}(Q\Sigma_B Q)}{\text{tr}(\Sigma_B)},$$

即位于同一候选编码器的参考数据子空间之外的类间协方差比例。该残差比例本身并不能证明信息是架构特有的，也不涉及不同编码器之间的比较。在完整 VTAB 支持（$24 \times 7 = 168$ 个架构–任务对）上，SA_k 与 f_{spe} 几乎完全负相关（$\rho_{\text{Sp}} = -0.959$，图 3）；逐任务内部，$f_{\text{spe}}$ 与 LP 准确率正相关（平均 Spearman 相关为 +0.420）。因此，减去子空间对齐度是一种有经验依据的无标签惩罚，用于惩罚与参考数据子空间的重叠；这只是机制证据，不是下游保证。由于 `resnet152` 只在八个 VTAB 数据集中的一个同时具备参考和目标特征，我们将其统一排除；最终 24 架构支持上的全部 168 对均成功计算。

对候选编码器 m，令未经额外中心化的特征矩阵为 $H_{m,T} \in \mathbb{R}^{n_T \times d_m}$ 和 $H_{m,R} \in \mathbb{R}^{n_R \times d_m}$。令 $V_T, V_R \in \mathbb{R}^{d_m \times k_m}$ 分别包含其前导右奇异向量，其中 $k_m = \min\{k, n_T, n_R, d_m\}$，默认 $k = 20$。若主角为 $\theta_1, \ldots, \theta_{k_m}$，则

$$\text{SA}_k(H_{m,T}, H_{m,R}) = \frac{1}{k_m} \|V_T^{\top} V_R\|_F^2 = \frac{1}{k_m} \sum_{i=1}^{k_m} \cos^2 \theta_i.$$

表 3: 完整 24 架构支持上的 VTAB 逐任务宽度混淆。STL-10 因作为参考数据集而排除。

任务	$\rho_{\mathrm{Sp}}(\mathrm{RankMe}, d)$	遗憾	RankMe 选择
CIFAR-10	+0.865	+0.050	efficientnet_b3 ($d = 1536$)
CIFAR-100	+0.869	+0.235	efficientnet_b3 ($d = 1536$)
DTD	+0.877	+0.095	resnet101 ($d = 2048$)
Fashion-MNIST	+0.886	+0.045	wide_resnet50_2 ($d = 2048$)
Flowers-102	+0.838	+0.165	efficientnet_b3 ($d = 1536$)
Pets	+0.902	+0.070	mobilenetv3_large ($d = 1280$)
SVHN	+0.915	+0.110	efficientnet_b3 ($d = 1536$)
平均	**+0.879**	**+0.110**	—

表 4: MV 119 候选逐任务 LP。随机列为精确期望。$\mathrm{SSR}^{\ddagger}$ 在四个任务优于 RankMe，在 SVHN 更差。EuroSAT 另有 ViT-large 并列 oracle（LP 0.955）。

任务	Oracle	随机	RM	$\mathrm{SSR}^{\ddagger}$	RM 选择	$\mathrm{SSR}^{\ddagger}$ 选择	Oracle 组
CIFAR-10	0.970	0.787	0.845	0.870	resnext50	resnet50	convnext_base
CIFAR-100	0.825	0.486	0.535	0.670	resnext50	resnet152	convnext_base
DTD	0.740	0.564	0.625	0.720	resnext50	convnext_base	convnext_base
EuroSAT	0.955	0.882	0.880	0.905	resnext50	efficientnet_b3	densenet201 (tie)
SVHN	0.615	0.428	0.500	0.450	inception_v3	efficientnet_b3	densenet169

完整计算见算法 1。候选模型的特征维度可以不同，因为不存在跨候选的子空间比较。

SCR 分数族定义为

$$\mathrm{SCR}(H, T; \beta, g) = \frac{\log r_{\mathrm{eff}}(H) + \beta g\big(\mathrm{SA}_k(H, H_{\mathrm{ref}})\big)}{\log C(T)},$$

其中 g 单调递减且 $\beta \geq 0$。取 $g(s) = -\log s$、$\beta = 1$ 得到实际用于全部主结果的分数

$$\boxed{\mathrm{SSR}^{\ddagger}(H, T) = \frac{\log r_{\mathrm{eff}}(H) - \log \mathrm{SA}_k(H, H_{\mathrm{ref}})}{\log C(T)}}.$$

对固定任务，正因子 $1/\log C(T)$ 不改变候选排序。该分数对共同表示基变换不变，但不是目标奇异值谱的单输入函数。

实现选择。我们将校正权重固定为 $\beta = 1$；k、参考数据和预处理仍是设计选择。使用 $k = 20$，不按目标标签调参，但该评估协议下对 k 的敏感性仍未验证（附录 D）。主评分采用非中心化 SVD，将对齐度下限裁剪为 10^{-12}，以保持对数有限。这项数值保护不保证统计稳定性。截断边界的并列奇异值遵循命题 2 的一致子空间约定。

选择 STL-10 是因为它规模小、内容多样、所有候选均支持，并与所评估 22 个池–任务单元的目标分离。默认采用一个通用且与目标分离的参考，在查看目标标签或准确率之前确定。其他领域应使用模态兼容、内容多样且样本量足以估计子空间的数据。在 24 架构 VTAB 支

表 5: 辅助方法的完整共同支持：剔除一个缺项变体后为 118 个候选，再移除三个 VGG 变体后为 115 个。数值为五任务平均遗憾。

方法	含 VGG	不含 VGG	Δ	类型
随机	0.192	0.191	−0.001	参照
RankMe	0.144	0.144	0.000	无标签
RankMe ($-\log d$)	0.200	0.200	0.000	无标签
LogME	0.219	0.550	0.331	有标签
H-score	0.470	0.470	0.000	有标签
NCTI	0.155	0.155	0.000	有标签
$\mathrm{SSR}^{\ddagger}$	0.098	0.098	0.000	无标签
LEEP 聚类代理	0.038	0.038	0.000	有标签

表 6: 辅助方法的完整共同支持：剔除一个缺项变体后为 118 个候选，再移除三个 VGG 变体后为 115 个。数值为五任务平均 LP。

方法	含 VGG	不含 VGG	Δ	类型
随机	0.629	0.630	0.001	参照
RankMe	0.677	0.677	0.000	无标签
RankMe $(-\log d)$	0.621	0.621	0.000	无标签
LogME	0.602	0.271	−0.331	有标签
H-score	0.351	0.351	0.000	有标签
NCTI	0.666	0.666	0.000	有标签
$\mathrm{SSR}^{\ddagger}$	0.723	0.723	0.000	无标签
LEEP 聚类代理	0.783	0.783	0.000	有标签

算法 1 单个候选的零标签 $\mathrm{SSR}^{\ddagger}$ 评分

Require: 编码器 m；非空无标签目标 T 和与其分离的参考 R，特征非零；$k = 20$；$\epsilon = 10^{-12}$

使用同一编码器及其固定预处理提取 $H_{m,T}$、$H_{m,R}$，缓存参考特征。

分别计算未经中心化的薄 SVD，保留目标奇异值 $\{\sigma_i\}$。

令 $k_m = \min\{k, n_T, n_R, d_m\}$，保留具有 k_m 列的右奇异向量基 V_T, V_R。

$s \leftarrow \|V_T^\top V_R\|_F^2 / k_m$。

$p_i \leftarrow \sigma_i / \sum_j \sigma_j$；$r \leftarrow \exp(-\sum_{i:p_i>0} p_i \log p_i)$。

$a \leftarrow \log\max(r, \epsilon) - \log\max(s, \epsilon)$。

return 若有类别数元数据 $C(T) > 1$，返回 $a / \log C(T)$；否则返回 a，逐任务排序相同。

持上，单参考遗憾为 0.061；四个预定参考的逐目标留一中位数集成（协议见下文）的遗憾为 0.055。考虑到证据仅来自七个任务，且需要额外参考侧计算，我们保留单参考作为默认设置。这是一种启发式选择。

目标分离的参考协议。集成消融预先固定 STL-10、CIFAR-10、Flowers-102 和 Pets 四个参考数据集。对每个评估目标，先从集合中移除同名数据集，再使用同一候选编码器分别计算目标与各剩余参考的对齐度。先对这些对齐度取中位数，再施加对数校正；不按目标准确率挑选参考，也不对不同编码器的分数取平均。在预处理不变时，每个候选的参考特征可缓存并跨目标复用。目标标签只用于事后的 LP 评估和类间方差诊断，不进入这一选择规则。该过程排除了直接的目标/参考数据集重合；对参考领域及样本组成的敏感性仍是开放问题（附录 D）。

在 MV 的 5 个任务、VTAB 的 7 个非参考任务以及 EX 的 10 个任务组成的 22 个共同支持池–任务单元上（表 9），$\mathrm{SSR}^{\ddagger}$ 的平均遗憾为 0.069，RankMe 为 0.133，随机选择为 0.137。$\mathrm{SSR}^{\ddagger}$ 减 RankMe 的配对差值是 -0.0645（单元 bootstrap 的 95% CI 为 $[-0.107, -0.028]$，$p = 0.00006$）。这些观测包含 10 个不同目标名称，其中 8 个跨模型池重复；按目标名称聚类重采样后，95% CI 为 $[-0.122, -0.020]$，双侧 $p = 0.00194$（100,000 次重采样），配对 Wilcoxon 检验为 $p = 0.00328$。Wilcoxon 对差值舍入到小数点后 10 位，零值处理为 `wilcox`，采用正态近似、无连续性修正，SciPy 1.15.3。

几何机制的验证使用完整 VTAB 支持上的 $24 \times 7 = 168$ 个架构–任务对。SA_k 与参考子空间之外的类间协方差比例 f_{spe} 的相关为 -0.959；逐任务内部，f_{spe} 与线性探针准确率的平均相关为 $+0.420$。这只是经验机制证据，不是 $\mathrm{SSR}^{\ddagger}$ 与下游准确率之间的理论界。

如何理解汇总结果。每个池内，各方法共享候选集和逐任务 oracle；不同池的候选集则有所不同。按目标名称 bootstrap 将被抽中目标的所有跨池记录一起重采样，以处理目标重复。所得区间以保留的特征缓存及 LP 协议为条件，不包含新预训练运行、参考选择或训练/测试划分带来的变化。因此，我们在汇总结果之外同时报告分池结果，不将结论直接外推至未见任务或模型库。

分池证据及其限制。表 8 分解同一组 22 单元；总体均值按各池任务数加权，而非对池等权。独立的 SSL 诊断只覆盖 232 个可能模型–任务单元中的 209 个，且历史 SSR 参考清单缺失。SSL 不纳入主文目标分离比较。

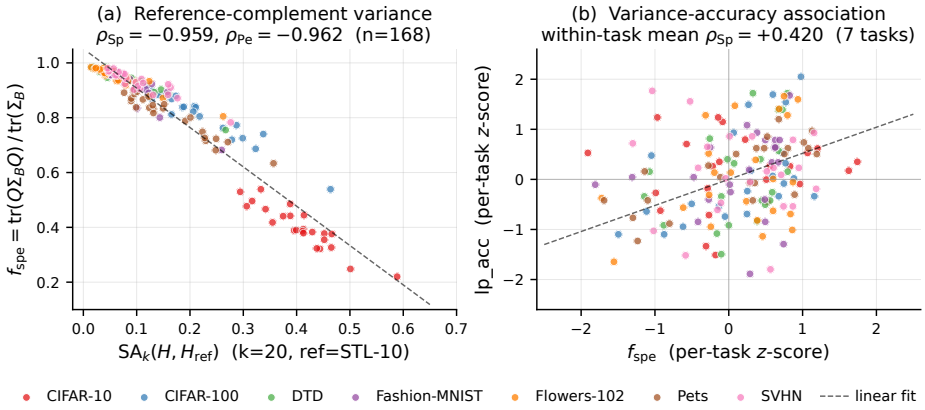


图 3: (a) 同一候选的目标特征与 STL-10 特征的对齐度，与该候选参考数据子空间之外的类均值方差比例 f_{spe} 近乎完全负相关；(b) 在每个任务内部，f_{spe} 与线性探针准确率正相关（七个任务的平均 Spearman 相关为 $+0.420$）。

有标签比较。官方分类 DiSCO 使用目标真实标签构造类条件协方差。表 7 报告 PCA-128 协议，分别采用 $G = 6$ 和 $G = 8$ 个连续、近似等大的谱分组（附录 C）。与 $\mathrm{SSR}^{\ddagger}$ 相比，这些数值显示的是依赖模型池的折衷，而非统一优越性：DiSCO 在 EX 上更好，VTAB 上的排序则依赖 G。其 SSL 数值 0.045/0.042 来自独立的诊断支持，不加入主实验汇总。这些比较描述了不同标签预算下的表现，因此与零标签比较分开报告。

表 7: 各模型池上的官方 PCA-128 分类 DiSCO；MV 与主比较一致，采用 119 候选。G 是连续、近等大小谱分组的数量；DiSCO 使用目标标签。

模型池	任务数	$G = 6$ 遗憾	$G = 8$ 遗憾
MV	5	0.145	0.145
VTAB（排除 STL-10）	7	0.067	0.040
EX	10	0.045	0.049
SSL	29	0.045	0.042

表 8: 主实验共同支持上的分池平均遗憾（越低越好）。使用与跨池表相同的观测，不增加实验；所有方法均排除 STL-10。

模型池	任务	RankMe	$\mathrm{SSR}^{\ddagger}$	差值
MV	5	0.1440	0.0980	−0.0460
VTAB	7	0.1100	0.0614	−0.0486
EX	10	0.1445	0.0595	−0.0850

同族排序。MV 的 173 个非恒定架构–任务组内，RankMe 和 $\mathrm{SSR}^{\ddagger}$ 的平均 Spearman 相关分别为 0.527、0.519。两种分数在这一描述性指标上接近，尚不足以据此偏好某一种同族评分方法。附录 F 给出组内和分阶段诊断。

6 两阶段与混合预算流程

算法 2 先用各架构的规范代表选出架构，再在该架构内排序变体；表 10 比较策略 S1–S8。在五个 MV 任务上，单阶段策略评估 119 个候选。$\mathrm{SSR}^{\ddagger}$ →RankMe（S5）平均不复用时评估 38 次（35 个规范代表和 3 个族内变体），复用阶段 1 的规范代表时为 37 次，遗憾 0.102，单阶段 $\mathrm{SSR}^{\ddagger}$ 为 0.098。五任务证据只支持概念验证，不提供普遍的成本或质量保证。

分阶段诊断。在同一 119 候选支持上，$\mathrm{SSR}^{\ddagger}$ →$\mathrm{SSR}^{\ddagger}$ 的遗憾为 0.101，接近 $\mathrm{SSR}^{\ddagger}$ →RankMe 的 0.102。阶段 2 使用 RankMe，是因为它只需目标特征，可避免为新评估变体提取参考特征。零标签替代方案 R_{UID} →RankMe（S7）的遗憾为 0.058，不复用/复用时评估 37.4/36.4

表 9: 22 个共同支持池–任务单元上的零标签跨池比较。官方分类 DiSCO 使用目标标签，故不列入此表。

方法	平均遗憾	标签预算	作用
随机选择	0.137	零	参照
RankMe	0.133	零	目标谱
$\mathrm{SSR}^{\ddagger}$	**0.069**	零	目标–参考几何

$\mathrm{SSR}^{\ddagger}$ 与 RankMe 的配对差值：$\Delta = -0.0645$；目标聚类 95% CI $[-0.122, -0.020]$，$p = 0.00194$。

算法 2 两阶段无源模型迁移性估计流程

1: **输入：**候选池 $\{(a, V_a)\}$、目标特征 H_T、参考特征 H_{ref}。
2: **阶段 1（架构）：**对每个架构 a 的规范代表 $\bar{v}_a \in V_a$ 计算分数 s_1，并令 $a^* = \arg\max_a s_1(\bar{v}_a, T)$。
3: **阶段 2（变体）:** 对 $v \in V_{a^*}$ 计算分数 s_2，返回 $v^* = \arg\max_v s_2(v, T)$。

表 10: MV 119 候选、五任务流程。区间为 100000 次任务 bootstrap。评估次数分别为不复用/复用规范代表；不含参考初始化。K 是使用标签的架构评估次数。

策略	平均 LP	遗憾	95% CI	次数
S1 Random	0.630	0.191	[0.118, 0.276]	1/1
S2 Flat-RankMe	0.677	0.144	[0.093, 0.220]	119/119
S3 Flat-$\mathrm{SSR}^{\ddagger}$	0.723	0.098	[0.048, 0.148]	119/119
S4 RankMe→RankMe	0.677	0.144	[0.093, 0.220]	38/37
S5 $\mathrm{SSR}^{\ddagger}$ →RankMe	0.719	0.102	[0.044, 0.153]	38/37
S6 $\mathrm{SSR}^{\ddagger}$ →$\mathrm{SSR}^{\ddagger}$	0.720	0.101	[0.051, 0.151]	38/37
S7 R_{UID} →RankMe	0.763	0.058	[0.005, 0.111]	37.4/36.4
S8 H-score→RankMe (有标签; $K = 35$)	0.803	0.018	[0.000, 0.052]	37/36

次。这里 UID 是 TwoNN 内在维度估计 [11]，$R_{\mathrm{UID}} = \log r_{\mathrm{eff}}/(\mathrm{UID} \log C)$ 将有效秩的对数除以该估计值及 $\log C$，而非直接按 UID 值对候选排序（附录 F）。全部 35 个规范代表分数均可用。这一替代方案在五任务的事后比较中优于所提流程。

混合预算版本。阶段 1 在随机抽取的 K 个架构代表上使用 H-score，阶段 2 保留 RankMe。K 表示使用标签的架构评估次数，不是标注样本数。每个预算在五任务上重复抽取 100 次，$K = 5$ 时平均遗憾 0.089、$K = 35$ 时为 0.018；实际不复用平均候选次数为 8.324、37。图 4 左图比较各策略的遗憾与评估次数，右图将混合预算曲线与零标签 S5、S7 对比。这仍是探索性的信息–计算折衷。

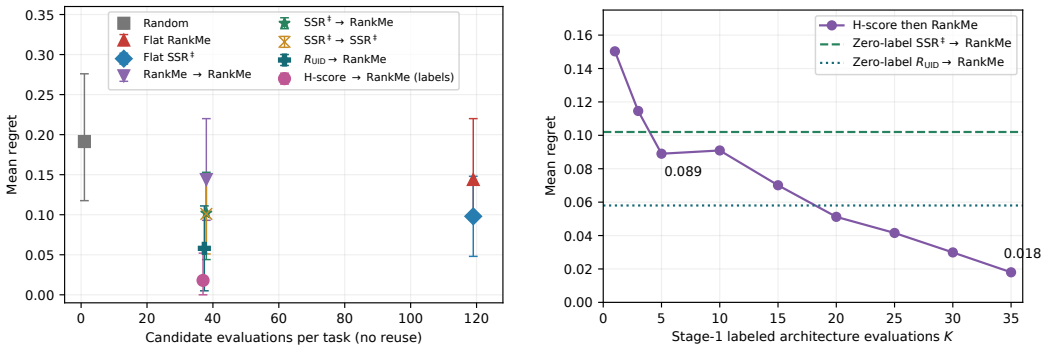


图 4: 五任务 MV 概念验证。左：遗憾与不复用的候选评估次数，附任务 bootstrap 区间；右：平均遗憾与使用标签的架构评估次数 K，不是标注样本数。

7 讨论与局限

计算口径。有记录的 MV/EX 特征提取启动器使用四个华为昇腾 NPU；VGG 提取使用 NVIDIA L20 GPU。评分与统计分析使用 CPU。候选评估次数不含参考初始化，不表示实测运行时间或能耗节省。附录 G 给出有记录的环境及其覆盖范围。

适用范围。SCR 最有力的证据来自异构架构之间的选择。同族内，RankMe 和 $\mathrm{SSR}^{\ddagger}$ 与准确率的平均相关接近。两阶段设计使用 RankMe，是为了避免第二阶段的额外参考特征提取，而非假定它在同族内更优。

校正捕获了什么。对齐度衡量每个候选特征空间内目标与参考的相对几何，并保持共同基变换不变性。低对齐度本身未必意味着特征有用：参考子空间之外的方向可能与目标标签无关，共享方向则可能具有判别性。VTAB 类间方差诊断为这一几何解释提供了经验支持。

参考缓存可在同一编码器的不同目标任务间复用，但不消除初始化成本，也不能跨编码器互换。使用 M 个参考数据集时，近似 M 倍成本作用于参考侧提取和对齐，而非端到端运行时间。

局限。参考选择仍是启发式的，目前也没有将对齐度或 $\mathrm{SSR}^{\ddagger}$ 与下游准确率联系起来的形式化界。集成比较仅覆盖七个 VTAB 任务（单参考遗憾 0.061、集成 0.055），其更广泛的价值仍不明确。MV 内的预处理差异可能影响评分及 LP oracle；两种 VGG 对照不能解决其他候选的这一问题。两阶段证据限于五个任务，且其中另一种零标签流程的遗憾更低。在提出广泛部署结论之前，仍需统一预处理并扩大评估。

8 结论

在不同架构间选择模型时，RankMe 可能将特征宽度与表示质量混淆。在固定长宽比的给定各向同性模型下，其有效秩按 $\Theta(d)$ 缩放。SCR 通过加入目标–参考子空间几何来应对这一问题，并以 $\mathrm{SSR}^{\ddagger}$ 作为默认分数。在 22 个共同支持池–任务单元上，$\mathrm{SSR}^{\ddagger}$ 相比 RankMe 将平均选择遗憾从 0.133 降至 0.069（配对差值：-0.0645；按目标名称聚类的 95% CI：$[-0.122, -0.020]$）。在 MV 上，平均分数–宽度相关从 0.609 降至 0.305，表明宽度依赖有所减弱，但未完全消除。核心发现是：在这些模型池上，目标–参考几何能够改善仅依赖目标谱的模型选择。全模型池的统一预处理、参考设计、下游保证及更广泛的两阶段验证仍是开放问题。

Acknowledgments and Disclosure of Funding

本工作得到“111 中心”（编号 B26023）和教育部基础学科与交叉学科突破计划（编号 JYB2025XDXM118）的支持。

利益冲突：作者声明不存在利益冲突。

参考文献

[1] Andrea Acevedo, Anna Merino, Santiago Alférez, Ángel Molina, Laura Boldú, and José Rodellar. A dataset of microscopic peripheral blood cell images for development of automatic recognition systems. *Data in Brief*, 30:105474, 2020.

[2] Walid Al-Dhabyani, Mohammed Gomaa, Hussien Khaled, and Aly Fahmy. Dataset of breast ultrasound images. *Data in Brief*, 28:104863, 2020.

[3] Patrick Bilic, Patrick Christ, et al. The liver tumor segmentation benchmark (LiTS). *Medical Image Analysis*, 84:102680, 2023. doi: 10.1016/j.media.2022.102680.

[4] Lukas Bossard, Matthieu Guillaumin, and Luc Van Gool. Food-101 – mining discriminative components with random forests. In *European Conference on Computer Vision (ECCV)*, volume 8694 of *Lecture Notes in Computer Science*, pages 446–461, 2014. doi: 10.1007/978-3-319-10599-4_29.

[5] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 9630–9640, 2021. doi: 10.1109/ICCV48922.2021.00951.

[6] Mircea Cimpoi, Subhransu Maji, Iasonas Kokkinos, Sammy Mohamed, and Andrea Vedaldi. Describing textures in the wild. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3606–3613, 2014. doi: 10.1109/CVPR.2014.461.

[7] Adam Coates, Honglak Lee, and Andrew Y. Ng. An analysis of single-layer networks in unsupervised feature learning. In *International Conference on Artificial Intelligence and Statistics (AISTATS)*, volume 15 of *Proceedings of Machine Learning Research*, pages 215–223, 2011.

[8] Noel Codella, Veronica Rotemberg, Philipp Tschandl, et al. Skin lesion analysis toward melanoma detection 2018: A challenge hosted by the international skin imaging collaboration (ISIC). *arXiv preprint arXiv:1902.03368*, 2019.

[9] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. ImageNet: A large-scale hierarchical image database. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 248–255, 2009.

[10] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*, 2021.

[11] Elena Facco, Maria d'Errico, Alex Rodriguez, and Alessandro Laio. Estimating the intrinsic dimension of datasets by a minimal neighborhood information. *Scientific Reports*, 7:12140, 2017.

[12] Basura Fernando, Amaury Habrard, Marc Sebban, and Tinne Tuytelaars. Unsupervised visual domain adaptation using subspace alignment. In *IEEE International Conference on Computer Vision (ICCV)*, pages 2960–2967, 2013.

[13] Quentin Garrido, Randall Balestriero, Laurent Najman, and Yann LeCun. RankMe: Assessing the downstream performance of pretrained self-supervised representations by their rank. In *International Conference on Machine Learning (ICML)*, volume 202 of *Proceedings of Machine Learning Research*, pages 10929–10974, 2023.

[14] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

[15] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 9726–9735, 2020. doi: 10.1109/CVPR42600.2020.00975.

[16] Patrick Helber, Benjamin Bischke, Andreas Dengel, and Damian Borth. EuroSAT: A novel dataset and deep learning benchmark for land use and land cover classification. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 12(7):2217–2226, 2019. doi: 10.1109/JSTARS.2019.2918242.

[17] Jonathan J. Hull. A database for handwritten text recognition research. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 16(5):550–554, 1994. doi: 10.1109/34.291440.

[18] Jakob Nikolas Kather, Johannes Krisam, et al. Predicting survival from colorectal cancer histology slides using deep learning: A retrospective multicenter study. *PLOS Medicine*, 16(1):e1002730, 2019.

[19] Daniel S. Kermany, Michael Goldbaum, et al. Identifying medical diagnoses and treatable diseases by image-based deep learning. *Cell*, 172(5):1122–1131.e9, 2018.

[20] Jaeill Kim, Suhyun Kang, Duhun Hwang, Jungwook Shin, and Wonjong Rhee. VNE: An effective method for improving deep representation by manipulating eigenvalue distribution. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3799–3810, 2023. doi: 10.1109/CVPR52729.2023.00370.

[21] Alex Krizhevsky. Learning multiple layers of features from tiny images. Technical report, University of Toronto, 2009.

[22] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.

[23] Ruhan Liu, Xiangning Wang, Qiang Wu, et al. DeepDRiD: Diabetic retinopathy—grading and image quality estimation challenge. *Patterns*, 3(6):100512, 2022. doi: 10.1016/j.patter.2022.100512.

[24] Zhuang Liu, Hanzi Mao, Chao-Yuan Wu, Christoph Feichtenhofer, Trevor Darrell, and Saining Xie. A ConvNet for the 2020s. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11966–11976, 2022. doi: 10.1109/CVPR52688.2022.01167.

[25] Vebjorn Ljosa, Katherine L. Sokolnicki, and Anne E. Carpenter. Annotated high-throughput microscopy image sets for validation. *Nature Methods*, 9(7):637, 2012.

[26] Subhransu Maji, Esa Rahtu, Juho Kannala, Matthew Blaschko, and Andrea Vedaldi. Fine-grained visual classification of aircraft. *arXiv preprint arXiv:1306.5151*, 2013.

[27] Makerere AI Lab. iBean: Bean disease dataset. Original dataset repository, 2020. URL https://github.com/AI-Lab-Makerere/ibean. Accessed November 4, 2026.

[28] Vladimir A. Marčenko and Leonid A. Pastur. Distribution of eigenvalues for some sets of random matrices. *Mathematics of the USSR-Sbornik*, 1(4):457–483, 1967.

[29] Yuval Netzer, Tao Wang, Adam Coates, Alessandro Bissacco, Bo Wu, and Andrew Y. Ng. Reading digits in natural images with unsupervised feature learning. In *NIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2011.

[30] Maria-Elena Nilsback and Andrew Zisserman. Automated flower classification over a large number of classes. In *Sixth Indian Conference on Computer Vision, Graphics and Image Processing*, pages 722–729, 2008. doi: 10.1109/ICVGIP.2008.47.

[31] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024.

[32] Omkar M. Parkhi, Andrea Vedaldi, Andrew Zisserman, and C. V. Jawahar. Cats and dogs. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3498–3505, 2012. doi: 10.1109/CVPR.2012.6248092.

[33] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 8748–8763, 2021.

[34] Semeion. Semeion Handwritten Digit [dataset]. UCI Machine Learning Repository, 1998. URL https://doi.org/10.24432/C5SC8V.

[35] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations (ICLR)*, 2015.

[36] Richard Socher, Alex Perelygin, Jean Wu, Jason Chuang, Christopher D. Manning, Andrew Y. Ng, and Christopher Potts. Recursive deep models for semantic compositionality over a sentiment treebank. In *Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1631–1642, 2013.

[37] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. The German Traffic Sign Recognition Benchmark: A multi-class classification competition. In *International Joint Conference on Neural Networks (IJCNN)*, pages 1453–1460, 2011.

[38] Mingxing Tan and Quoc V. Le. EfficientNet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, volume 97 of *Proceedings of Machine Learning Research*, pages 6105–6114, 2019.

[39] Philipp Tschandl, Cliff Rosendahl, and Harald Kittler. The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5:180161, 2018.

[40] Ross Wightman. PyTorch Image Models. Software, 2019. URL https://github.com/rwightman/pytorch-image-models.

[41] Han Xiao, Kashif Rasul, and Roland Vollgraf. Fashion-MNIST: A novel image dataset for benchmarking machine learning algorithms. *arXiv preprint arXiv:1708.07747*, 2017.

[42] Xuanang Xu, Fugen Zhou, Bo Liu, Dongshan Fu, and Xiangzhi Bai. Efficient multiple organ localization in CT image using 3D region proposal network. *IEEE Transactions on Medical Imaging*, 38(8):1885–1898, 2019. doi: 10.1109/TMI.2019.2894854.

[43] Jiancheng Yang, Rui Shi, Donglai Wei, Zequan Liu, Lin Zhao, Bilian Ke, Hanspeter Pfister, and Bingbing Ni. MedMNIST v2—a large-scale lightweight benchmark for 2D and 3D biomedical image classification. *Scientific Data*, 10(1):41, 2023.

[44] Xiaohua Zhai, Joan Puigcerver, Alexander Kolesnikov, Pierre Ruyssen, Carlos Riquelme, Mario Lucic, Josip Djolonga, Andre Susano Pinto, Maxim Neumann, Alexey Dosovitskiy, Lucas Beyer, Olivier Bachem, Michael Tschannen, Marcin Michalski, Olivier Bousquet, Sylvain Gelly, and Neil Houlsby. A large-scale study of representation learning with the visual task adaptation benchmark. *arXiv preprint arXiv:1910.04867*, 2019.

[45] Tengxue Zhang, Yang Shu, Xinyang Chen, Yifei Long, Chenjuan Guo, and Bin Yang. Assessing pre-trained models for transfer learning through distribution of spectral components. *Proceedings of the AAAI Conference on Artificial Intelligence*, 39(21):22560–22568, 2025. doi: 10.1609/aaai.v39i21.34414.

补充材料

无标签跨架构模型选择中的宽度混淆：诊断与子空间校正
Qin Liu、Chen Zhong、Fengshan Zhao
附录 A–G 与正文配套使用；参考文献编号对应正文中的参考文献表。

A Marchenko–Pastur 定律与各向同性

引理证明. 写作 $r_{\mathrm{eff}}(H) = \exp(H_{\mathrm{ent}}(\mathbf{p}))$，其中 RankMe 使用 $p_i = \sigma_i / \sum_j \sigma_j$。令 $\lambda_i = \sigma_i^2/(n\sigma^2)$，经验测度包含全部 d 个特征值，包括 $d > n$ 时的零特征值。由 Marchenko–Pastur 定律 [28]，该测度几乎处处收敛到 μ_γ。定义 $S_d = d^{-1}\sum_j \sqrt{\lambda_j}$ 与 $m_{1/2} = \int \sqrt{x}\,\mathrm{d}\mu_\gamma(x)$。公共尺度 $\sigma\sqrt{n}$ 在 RankMe 中抵消，并有有限维恒等式

$$H_{\mathrm{ent}}(\mathbf{p}) = \log d + \log S_d - \frac{1}{2S_d}\frac{1}{d}\sum_i \sqrt{\lambda_i}\log\lambda_i.$$

因此，取 $0\log 0 = 0$，MP 极限给出

$$H_{\mathrm{ent}}(\mathbf{p}) = \log d + \log m_{1/2} - \frac{1}{2m_{1/2}}\int \sqrt{x}\log x\,\mathrm{d}\mu_\gamma(x) + o(1).$$

对任意固定正长宽比，上述矩均有限，包括谱支撑到达零或在零点存在原子的情形。因此 $r_{\mathrm{eff}}(H)/d \to c(\gamma) > 0$，即 $r_{\mathrm{eff}}(H) = \Theta(d)$。 □

命题 2 的证明. 若 $H = U\Sigma V^\top$，则 $HQ = U\Sigma(Q^\top V)^\top$。两个保留基分别变为 $V_T' = Q^\top V_T$、$V_R' = Q^\top V_R$，故 $(V_T')^\top V_R' = V_T^\top Q Q^\top V_R = V_T^\top V_R$。奇异值与经过裁剪的分数也不变。为说明目标谱不足以确定分数，固定沿 e_1 的秩一参考，令具有相同奇异值的秩一目标的右方向为 $\cos\theta\, e_1 + \sin\theta\, e_2$。当 $k_m = 1$ 时，对齐度为 $\cos^2\theta$，从而可在目标谱不变时改变分数。若截断边界穿过并列奇异值块，必须一致地选择子空间；任意独立的 SVD 并列处理不在不变性命题的范围内。 □

类别总方差诊断。VTAB 上可获得诊断的架构–任务对中，$\eta_\Sigma = \mathrm{Var}_c[\mathrm{tr}(\Sigma_c)]/(\mathbb{E}_c[\mathrm{tr}(\Sigma_c)])^2$ 的中位数为 0.022、均值为 0.035，且 93.3% 小于 0.1。它衡量各类总方差的相似性，而非方向上的各向同性：相同的各向异性类协方差也能给出 $\eta_\Sigma = 0$。因此，该统计量不用于验证引理 1 的各向同性假设；该假设定义的是解释性模型，而非对所有预训练表示均已验证的性质。

宽度图的协议。VTAB 系列采用非中心化 SVD 和 RankMe 奇异值有效秩。该谱诊断的架构均值使用八个缓存数据集，但目标选择排除 STL-10。EX 使用保留的 RankMe 分数。MV 的记录分组键内部可能具有不同宽度，故该图不画 MV，另报告按变体计算的 MV 相关。

B MV 池（多变体池）

数据集来源。CIFAR-10/100 来自 Krizhevsky [21]，DTD 来自 Cimpoi et al. [6]，EuroSAT 来自 Helber et al. [16]，SVHN 来自 Netzer et al. [29]。ImageNet [9] 是监督预训练候选的预训练数据集，不是主汇总中的目标。

设置。MV 模型清单包含 132 个 ImageNet-1k 预训练变体；架构选择和两阶段比较使用属于至少含两个变体的 35 个架构族的固定的 119 个变体支持集。所有模型来自 timm [40] 和 torchvision，并在 CIFAR-10、CIFAR-100、DTD、EuroSAT、SVHN 五个目标任务上评估。架构涵盖 VGG [35]、ResNet [14]、DenseNet、EfficientNet [38]、MobileNet、RegNet、ViT [10]、DeiT、ConvNeXt [24]、Swin 等，宽度从 ViT/DeiT-tiny 的 192 到 VGG-16 的 4096，跨度约 21 倍。LP 真值采用与 VTAB 相同的 80/20 划分和 $C = 1$ 的 ℓ_2 正则逻辑回归。各分组键及变体数见表 11。

宽度诊断。MV RankMe–宽度逐任务相关为 0.588 至 0.631，均值 0.609。RankMe 遗憾 0.144 低于精确随机期望 0.1914，但高于 $\mathrm{SSR}^\ddagger$ 的 0.098。移除 VGG 不改变这两种分数的遗憾。SVHN oracle 为 DenseNet-169。EuroSAT 有两个并列 oracle 变体：DenseNet-201 和 ViT-large，LP 均为 0.955。

表 11: MV 固定多变体支持的架构分组键与变体数，共 35 组、119 个变体。ResNet 等大类包含多个分组键。

分组键	变体数	分组键	变体数
convnext_base	2	regnet	8
convnext_small	3	resnet101	4
convnext_tiny	3	resnet152	4
deit_base	2	resnet18	3
deit_small	2	resnet34	3
deit_tiny	2	resnet50	11
densenet121	3	resnext50	3
densenet169	3	swin_small	4
densenet201	3	swin_tiny	3
efficientnet_b0	3	tf_efficientnet	2
efficientnet_b2	3	vgg16	3
efficientnet_b3	3	vit_b32	2
efficientnet_b4	2	vit_base	9
inception_v3	3	vit_large	2
mixer_b16	2	vit_small	4
mnasnet	3	vit_tiny	2
mobilenet_v3_large	4	wide_resnet50_2	3
mobilenet_v3_small	3		

多变体结构。模型清单包含 48 组、132 个变体，主支持为 35 个多变体组、119 个变体。VGG16-BN 是主支持之外的单成员组。规范代表取每组按字典序排列的首个变体。单阶段评估为 119 次。完整 132 候选池的 RankMe、SSR‡ 诊断遗憾分别为 0.152、0.082，有各自的 oracle，与主支持比较分开报告。

来源与 LP 敏感性。每个 torchvision VGG 模型均有三种提取设置的目标及 STL-10 缓存：25088 维展平特征、4096 维双重变换、4096 维一次官方变换。清单记录路径、时间戳、缓存/权重/脚本哈希、LP 划分、预测和求解器版本。独立检查验证全部 36 个缓存，并复现两种 4096 维设置下全部 20 个 LP 单元的预测。这两种设置及测试的 scikit-learn 版本（1.6.1 和 1.2.2）给出相同的 22 单元 RankMe/SSR‡ 遗憾，尽管个别 VGG 的 LP 准确率可能不同。该敏感性测试不证明辅助指标或未测试候选的协议等价。

版本来源与更正。 早期版本使用 torchvision VGG 的 25088 维展平特征，却描述为 4096 维倒数层特征。当前模型清单替换两个 VGG 模型的十个目标行，另外 650 行保持不变。22 单元的 SSR 减 RankMe 差值从 -0.1043 变为 -0.0645，且 MV RankMe 优于随机。早期的 MV 差于随机、无充分支持的 CNN-only/Transformer-only 效应、普遍同族优势等主张不受支持。有效秩归一化、官方有标签 DiSCO、目标分离参考比较和候选支持集均以当前协议为准。原始受影响缓存的来源不完整；新清单记录替换数据，而非重建该历史。

C SSL/多模态池

额外数据集来源。除附录 B、D、E 引用的数据集外，SSL 模型清单还包含 MNIST [22]、USPS [17]、GTSRB [37]、Semeion [34] 和 Beans [27]。CIFAR-100-coarse 使用 CIFAR-100 的超类标签 [21]。Rendered-SST2 是 CLIP [33] 使用的 Stanford Sentiment Treebank [36] 图像渲染版本。Beans 和 Semeion 引用原始数据发布记录，而不假定存在独立论文。

十一个生物医学任务使用 MedMNIST [43]：PathMNIST（结直肠组织学图像 [18]）、DermaMNIST（HAM10000/ISIC [8, 39]）、OCTMNIST 和 PneumoniaMNIST [19]、RetinaMNIST（DeepDRiD [23]）、BreastMNIST [2]、BloodMNIST [1]、TissueMNIST [25]，以及 OrganAMNIST/OrganCMNIST/OrganSMNIST（LiTS 图像及器官标注 [3, 42]）。这些引用区分了标准化任务与底层图像来源；我们不声称采集了这些图像。

设置。我们从 8 个 SSL/多模态编码器提取倒数第二层特征：ResNet-50/101、MoCo-v3-R50、ConvNeXt-B、ViT-B/16、CLIP-ViT-L/14、DINOv2-ViT-B/14 和 DINO-ViT-S/16。特征维度 $d \in \{384, 768, 1024, 2048\}$，不含 VGG 类架构。评估使用覆盖 VTAB、MedMNIST 变体和标准迁移基准的 29 个下游任务，LP 真值采用与 MV 相同的 80/20 逻辑回归协议。

可用支持与范围。留存的 SSL 表包含 $8 \times 29 = 232$ 个可能单元中的 209 个。23 个任务各有八个候选，FGVC-Aircraft 有四个，Flowers-102、Food-101、Oxford-Pets 和 Rendered-SST2 各有五个，Semeion 只有一个。Oracle 在可用候选内计算，因此 Semeion 的选择遗憾必为零。官方 DiSCO 与同一组 209 个 LP 单元匹配。这些历史诊断不是完整矩形基准，不纳入 22 单元主比较。历史 SSR 脚本指定 ImageNet 参考特征，并设有逐模型 CIFAR-10 回退路径，但没有保留逐次运行的参考清单。因此，其 SSR 列不被视为已验证的目标分离 STL-10 评估，也不用于支撑主校正结论。

诊断限制。SSL 支持不完整且缺少逐次运行的参考清单，因此不能在主实验的目标分离协议下完整对齐 RankMe/SSR‡ 比较。官方 DiSCO 结果是可用 209 单元上的描述性结果，与主实验零标签比较分开呈现。

有标签比较。官方 PCA-128 DiSCO 在可用的 29 个 SSL 任务上，$G = 6/8$ 的遗憾为 0.045/0.042；完整特征评分为 0.057/0.047，属于不同维度设置。官方分类 DiSCO 使用目标真实标签形成类条件协方差，因此与零标签 SSR‡–RankMe 比较分开报告。

正文表 7 汇总这些有标签结果及 MV、VTAB、EX 的对应结果。

D VTAB 池

数据集来源。除附录 B 中的共同来源，本池使用 Fashion-MNIST [41]、Flowers-102 [30]、Oxford-IIIT Pets [32] 和 STL-10 [7]。`pets` 与 `oxford_pets` 指同一数据集。"VTAB 池"指本文保留的评估池，不表示复现完整的原始 VTAB 套件 [44]。

设置。最终共同模型池包含在八个 VTAB 数据集（CIFAR-10/100、DTD、Fashion-MNIST、Flowers-102、Pets、STL-10、SVHN）上同时拥有完整特征和 LP 值的 24 个 timm 预训练架构。原始清单还列出 ResNet-152，但其八个特征文件只有一个可用，因此我们统一排除，而不让候选集随任务变化。STL-10 特征只作为 SA_k 的参考，并从共同支持目标中排除。

参考协议与固定 k。协议采用未经额外中心化的 SVD 和 RankMe 的奇异值归一化，并排除 STL-10 目标。$k = 20$ 时，以 STL-10 为单参考，在完整 24 架构支持的其余七个任务上遗憾为 0.061。参考敏感性只使用目标与参考分离的比较。我们固定使用 $k = 20$，不按目标标签调参。该最终评估协议下对 k 的敏感性尚未验证。

评估支持。模型清单含 660 个 MV、510 个 EX 和 192 个 VTAB 模型–任务单元，其中 168 个 VTAB 单元对应非参考目标。22 单元汇总使用 MV 多变体支持、全部七个非参考 VTAB 目标及十个 EX 目标。七任务单参考与集成遗憾分别为 0.061/0.055。

多参考稳健性。为实现目标不重叠的评估，当当前目标与参考名称相同，就从预先确定的 STL-10、CIFAR-10、Flowers-102、Pets 集合中删去该参考，并对其余对齐度取中位数。该逐目标留一集成遗憾为 0.055，单独使用 STL-10 为 0.061。考虑到证据仅来自七个任务，且参考侧成本约为 M 倍，我们保留单参考作为默认设置。参考设计仍是开放问题。

E EX 池与阶段 1 比较

数据集来源。FGVC-Aircraft [26] 和 Food-101 [4] 补充了附录 B、D 引用的八个目标数据集；STL-10 不是 EX 目标。

EX 池。EX 包含来自 35 个规范架构的 51 个 ImageNet-1k 监督预训练变体，其中包括 $d = 4096$ 的 VGG-16，$d_{\max}/d_{\min} = 21.3$。十个目标涵盖细粒度识别（FGVC-Aircraft、Flowers-102、Food-101、Oxford-Pets）、纹理/场景（DTD、EuroSAT）、数字/服饰（SVHN、Fashion-MNIST）和通用物体（CIFAR-10/100），特征在完整数据集上提取。Flat-SSR‡ 遗憾为 0.0595，RankMe 为 0.1445。依赖目标标签的官方 DiSCO 在 $G = 6/8$ 时为 $+0.045/+0.049$，不纳入零标签比较。

完整支持的辅助比较见表 5。

谱截断。完整 118 候选辅助支持上，top-256 RankMe 遗憾为 0.134，介于完整谱 RankMe 的 0.144 和 SSR‡ 的 0.098 之间。相应的截断分数 →RankMe 两阶段遗憾为 0.136，SSR‡ →RankMe 为 0.102。这些是特定设置中的观察，不证明截断本质上不适用。

F 消融与负结果

信息预算。DiSCO 使用目标标签，$\mathrm{SSR}^{\ddagger}$ 不使用。宽度范围本身不是在二者间选择的已验证标准。默认关系分数将权重固定为一，不进行跨池调参。

校正的代数形式。MV 上，$-\alpha \log \mathrm{SA}_k$ 在测试点 $\alpha = 0.5, 1, 2$ 的遗憾分别为 0.098、0.098、0.093。三个离散点不证明整个连续区间稳定。完整 118 候选辅助支持上，加法变体 $g(s) = 1 - s$、$\beta = 1$ 的遗憾为 0.117。其实现分数 $(\log r_{\mathrm{eff}} - s)/\log C$ 与家族定义相差任务内常数 $1/\log C$，因此排序及遗憾一致，但原始分数不同。反向控制 $-\log(1 - \mathrm{SA}_k)$ 为 0.388。保持 $\alpha = 1$ 而不利用目标表现调参，这些对照仅展示关系项形式的敏感性。

逐任务选择。选择和 oracle 见表 4。RankMe 在四任务选择 ResNeXt，在 SVHN 选择 Inception。$\mathrm{SSR}^{\ddagger}$ 在四个配对任务比较中更优，但在 SVHN 更差。

UID 归一化分数。定义 $R_{\mathrm{UID}} = \log r_{\mathrm{eff}}/(\mathrm{UID} \log C)$，其中 UID 为保留的 TwoNN 内在维度估计 [11]。该分数将有效秩的对数除以 UID 及 $\log C$，而非直接按 UID 值对候选排序。完整 118 候选辅助支持上，单阶段 R_{UID} 遗憾为 0.364，$\mathrm{SSR}^{\ddagger}$ 为 0.098。但 $R_{\mathrm{UID}} \rightarrow$RankMe 在该支持及主实验 119 候选上均为 0.058：虽然一个非规范代表的辅助单元缺失，全部 35 个阶段 1 规范代表分数均可用。因此，单阶段排名较差不一定意味着第一阶段筛选较差。这项五任务事后比较优于所评估的 $\mathrm{SSR}^{\ddagger}$ 流程，但不构成通用 UID 选择规则。

窄池适用范围。现有证据不能仅根据 CNN/Transformer 归属确定普遍更优的分数。关于同质子池的主张需要匹配的候选与任务支持。

同族排序与任务缩放。35×5 个架构–任务组中，两组的 LP 为常数；剩余 173 组的平均组内 Spearman 相关为 RankMe 0.527、$\mathrm{SSR}^{\ddagger}$ 0.519。这只是描述性结果，不是显著优越性主张。固定任务内，包括 $1/\log C(T)$ 在内的公共正比例缩放不改变候选排序。我们聚合逐任务遗憾而非原始分数。

G 实验环境与计算资源核算

NPU 特征提取。MV/EX DiSCO 特征提取启动器使用 PyTorch 与 `torch_npu`/Ascend，四个 NPU 设备（0–3），每设备一个模型分片，批大小 64，推理模式与 float32 缓存。这并不能确定每份历史缓存的硬件来源。

缓存特征分析。DiSCO、线性探针、参考比较与 bootstrap 使用 CPU 上的 NumPy/SciPy/scikit-learn 程序。MV/EX DiSCO 启动器使用 16 个工作进程；缓存避免为不同分数重复编码器推理。

VGG 提取环境。两个 VGG 模型使用 NVIDIA L20（约 46 GB）、批大小 64、float32 缓存、PyTorch 2.5.1+cu124、torchvision 0.20.1、Python 3.11.11、NumPy 1.26.4、SciPy 1.15.3 和 scikit-learn 1.6.1。主机暴露 16 个 CPU 线程、约 123 GiB 内存，评分限制为八线程。LP 使用 seed=0 分层 800/200 划分、仅在训练集拟合 StandardScaler、$C = 1$、lbfgs、max_iter=1000。隔离的 sklearn 1.2.2 对照改变部分 VGG LP，但不改变主实验遗憾。缓存和脚本哈希、实际生成时间均已记录。

报告范围。第 6 节统计候选–任务评估次数，而非运行时间、能耗或硬件加速比；参考初始化另计。历史硬件、软件和运行时间记录不完整，无法完整报告计算资源，检查清单中该项仍回答“否”。

NeurIPS 论文核查表

1. **论断**

   问题：摘要和引言中的主要论断是否准确反映论文贡献与范围？

   回答：[Yes]

   说明：摘要及第 1、7 节明确陈述了 RankMe 特有的宽度混淆、SSR‡ 的跨架构族范围、22 单元结果和主要局限。五任务两阶段结果被明确限定为概念验证，而非一般保证。

2. **局限**

   问题：论文是否讨论了本工作的局限？

   回答：[Yes]

   说明：第 7 节讨论了启发式参考选择、依赖模型池的性能、缺少形式化下游准确率保证、有限的同族证据和不完整的历史来源，两阶段流程只有五个任务的有限证据，以及保留 MV 候选间的预处理异质性。五任务诊断还包含遗憾更低的零标签流程。

3. **理论假设与证明**

   问题：每项理论结果是否给出完整假设与完整、正确的证明？

   回答：[Yes]

   说明：第 4 节给出 RankMe 结论所需的各向同性随机特征和长宽比假设，附录 A 使用 RankMe 的奇异值归一化给出 Marchenko–Pastur 推导。形式结论没有推广到任意旋转不变分数。

4. **实验结果可复现性**

   问题：论文是否充分披露复现主要实验结果及其结论所需的信息，无论是否提供代码和数据？

   回答：[No]

   说明：第 5 节给出有效秩、子空间对齐和 SSR‡ 的精确定义及算法。第 3 节和附录 B–G 记录支持集、VGG 提取设置、固定 LP 参数和缓存/脚本来源。保留结果表可核验汇总；部分原始缓存及历史环境未恢复，不能声称端到端历史复现。

5. **数据和代码的开放获取**

   问题：论文是否开放数据和代码，并提供足以忠实复现主要结果的说明？

   回答：[No]

   说明：配套仓库 https://github.com/kenny67nju/crossarchitecturetransferability 提供评分与分析代码、最终结果表、来源记录和核验说明。VGG 原始特征缓存不随仓库分发，部分历史缓存及环境不可用，因此尚未提供完整开放数据复现。

6. **实验设置与细节**

   问题：论文是否说明理解结果所需的全部训练和测试细节？

   回答：[Yes]

   说明：第 3 节描述模型池、线性探针协议、采样及逐候选预处理；第 5 节规定参考、k、裁剪、DiSCO 设置及汇总不确定性分析；第 6 节规定两阶段评估。附录 B–G 补充各池支持集、提取和 LP 设置、消融及有记录的计算环境。编码器保持冻结，仅拟合用于评估的线性探针。历史复现与计算资源记录的缺口见第 4、8 项。

7. **实验统计显著性**

   问题：论文是否恰当定义并报告误差条或其他统计显著性信息？

   回答：[Yes]

   说明：第 5 节的 22 单元主比较报告单元配对 bootstrap、按目标名称聚类的 95% 置信区间与双侧检验；聚类分析使用 100,000 次重采样，并由配对 Wilcoxon 检验佐证。第 6 节报告五任务两阶段区间及其有限证据范围。

8. **实验计算资源**

问题：论文是否为每项实验提供充分的计算资源、内存和运行时间信息？

回答：[No]

说明：附录 G 描述了 NVIDIA L20 VGG 提取及有记录的华为昇腾 NPU 特征提取启动器、四设备分片配置及基于 CPU 的缓存特征分析。历史运行未一致保留精确硬件规格、软件版本快照和完整的逐次运行时间，因此现有信息仍不足以构成完整的计算资源报告。前向评估次数与实测运行时间加速比已作区分。

9. **伦理规范**

问题：研究是否在各方面符合 NeurIPS 伦理规范 https://neurips.cc/public/EthicsGuidelines？

回答：[Yes]

说明：本工作在既有图像分类基准上评估预训练编码器并提出模型选择分数，不涉及人类受试者、私有数据或部署干预；作者已核查 NeurIPS 伦理规范。

10. **更广泛影响**

问题：论文是否讨论工作的潜在正面与负面社会影响？

回答：[N/A]

说明：这是选择既有预训练编码器的基础方法，可能减少不必要的模型评估；除底层预训练模型和基准数据本身的影响外，它不引入直接、特定于应用的社会影响。

11. **安全保障**

问题：对于具有高误用风险的数据或模型，论文是否说明了负责任发布所采用的保障措施？

回答：[N/A]

说明：发布内容是评分与分析代码及数值结果表；没有发布新的预训练模型、抓取数据集、生成系统或其他高风险资产。

12. **既有资产的许可**

问题：论文是否适当标注所用代码、数据和模型的创作者，并明确说明和遵守许可及使用条款？

回答：[No]

说明：附录 B–E 引用了数据集原始论文或发布记录，包括派生数据集的底层来源。我们未提供涵盖全部数据集、模型权重和代码库的逐项许可证及使用条款清单，因此回答 No，而不声称许可文档完整。

13. **新资产**

问题：论文引入的新资产是否有完善文档，并随资产一同提供？

回答：[No]

说明：评分代码、结果表、验证脚本和特征提取说明均在仓库中记录，但当前发布版本没有单独的软件许可证文件。

14. **众包与人类受试者研究**

问题：若涉及众包或人类受试者，论文是否提供参与者说明全文、截图和报酬细节？

回答：[N/A]

说明：本研究未进行众包，也不涉及人类受试者。

15. **机构审查委员会批准**

    问题：论文是否说明参与者风险、风险告知和 IRB 或所在国家/机构的等价审批？

    回答：[N/A]

    说明：本研究不涉及人类受试者或研究参与者，因此 IRB 批准与参与者风险披露不适用。

16. **LLM 使用声明**

    问题：如果 LLM 是核心方法中重要、原创或非标准的组成部分，论文是否说明其使用？

    回答：[N/A]

    说明：LLM 不是所提出评分方法的组成部分。使用 AI 辅助进行文稿编辑、概念总览图制作及代码与审计支持；数学分数和报告的评估由所记录的数值程序计算，而非由 LLM 判断。作者对文本、图、代码和结果的核验承担责任。