补充材料

无标签跨架构模型选择中的宽度混淆：诊断与子空间校正
Qin Liu、Chen Zhong、Fengshan Zhao
附录 A–G 与正文配套使用；参考文献编号对应正文中的参考文献表。

A Marchenko–Pastur 定律与各向同性

引理证明. 写作 $r_{\mathrm{eff}}(H) = \exp(H_{\mathrm{ent}}(\mathbf{p}))$，其中 RankMe 使用 $p_i = \sigma_i / \sum_j \sigma_j$。令 $\lambda_i = \sigma_i^2/(n\sigma^2)$，经验测度包含全部 d 个特征值，包括 $d > n$ 时的零特征值。由 Marchenko–Pastur 定律 [28]，该测度几乎处处收敛到 μ_γ。定义 $S_d = d^{-1}\sum_j \sqrt{\lambda_j}$ 与 $m_{1/2} = \int \sqrt{x}\,\mathrm{d}\mu_\gamma(x)$。公共尺度 $\sigma\sqrt{n}$ 在 RankMe 中抵消，并有有限维恒等式

$$H_{\mathrm{ent}}(\mathbf{p}) = \log d + \log S_d - \frac{1}{2S_d}\frac{1}{d}\sum_i \sqrt{\lambda_i}\log\lambda_i.$$

因此，取 $0\log 0 = 0$，MP 极限给出

$$H_{\mathrm{ent}}(\mathbf{p}) = \log d + \log m_{1/2} - \frac{1}{2m_{1/2}}\int \sqrt{x}\log x\,\mathrm{d}\mu_\gamma(x) + o(1).$$

对任意固定正长宽比，上述矩均有限，包括谱支撑到达零或在零点存在原子的情形。因此 $r_{\mathrm{eff}}(H)/d \to c(\gamma) > 0$，即 $r_{\mathrm{eff}}(H) = \Theta(d)$。 □

命题 2 的证明. 若 $H = U\Sigma V^\top$，则 $HQ = U\Sigma(Q^\top V)^\top$。两个保留基分别变为 $V_T' = Q^\top V_T$、$V_R' = Q^\top V_R$，故 $(V_T')^\top V_R' = V_T^\top Q Q^\top V_R = V_T^\top V_R$。奇异值与经过裁剪的分数也不变。为说明目标谱不足以确定分数，固定沿 e_1 的秩一参考，令具有相同奇异值的秩一目标的右方向为 $\cos\theta\, e_1 + \sin\theta\, e_2$。当 $k_m = 1$ 时，对齐度为 $\cos^2\theta$，从而可在目标谱不变时改变分数。若截断边界穿过并列奇异值块，必须一致地选择子空间；任意独立的 SVD 并列处理不在不变性命题的范围内。 □

类别总方差诊断。VTAB 上可获得诊断的架构–任务对中，$\eta_\Sigma = \mathrm{Var}_c[\mathrm{tr}(\Sigma_c)]/(\mathbb{E}_c[\mathrm{tr}(\Sigma_c)])^2$ 的中位数为 0.022、均值为 0.035，且 93.3% 小于 0.1。它衡量各类总方差的相似性，而非方向上的各向同性：相同的各向异性类协方差也能给出 $\eta_\Sigma = 0$。因此，该统计量不用于验证引理 1 的各向同性假设；该假设定义的是解释性模型，而非对所有预训练表示均已验证的性质。

宽度图的协议。VTAB 系列采用非中心化 SVD 和 RankMe 奇异值有效秩。该谱诊断的架构均值使用八个缓存数据集，但目标选择排除 STL-10。EX 使用保留的 RankMe 分数。MV 的记录分组键内部可能具有不同宽度，故该图不画 MV，另报告按变体计算的 MV 相关。

B MV 池（多变体池）

数据集来源。CIFAR-10/100 来自 Krizhevsky [21]，DTD 来自 Cimpoi et al. [6]，EuroSAT 来自 Helber et al. [16]，SVHN 来自 Netzer et al. [29]。ImageNet [9] 是监督预训练候选的预训练数据集，不是主汇总中的目标。

设置。MV 模型清单包含 132 个 ImageNet-1k 预训练变体；架构选择和两阶段比较使用属于至少含两个变体的 35 个架构族的固定的 119 个变体支持集。所有模型来自 timm [40] 和 torchvision，并在 CIFAR-10、CIFAR-100、DTD、EuroSAT、SVHN 五个目标任务上评估。架构涵盖 VGG [35]、ResNet [14]、DenseNet、EfficientNet [38]、MobileNet、RegNet、ViT [10]、DeiT、ConvNeXt [24]、Swin 等，宽度从 ViT/DeiT-tiny 的 192 到 VGG-16 的 4096，跨度约 21 倍。LP 真值采用与 VTAB 相同的 80/20 划分和 $C = 1$ 的 ℓ_2 正则逻辑回归。各分组键及变体数见表 11。

宽度诊断。MV RankMe–宽度逐任务相关为 0.588 至 0.631，均值 0.609。RankMe 遗憾 0.144 低于精确随机期望 0.1914，但高于 $\mathrm{SSR}^\ddagger$ 的 0.098。移除 VGG 不改变这两种分数的遗憾。SVHN oracle 为 DenseNet-169。EuroSAT 有两个并列 oracle 变体：DenseNet-201 和 ViT-large，LP 均为 0.955。

表 11: MV 固定多变体支持的架构分组键与变体数，共 35 组、119 个变体。ResNet 等大类包含多个分组键。

分组键	变体数	分组键	变体数
convnext_base	2	regnet	8
convnext_small	3	resnet101	4
convnext_tiny	3	resnet152	4
deit_base	2	resnet18	3
deit_small	2	resnet34	3
deit_tiny	2	resnet50	11
densenet121	3	resnext50	3
densenet169	3	swin_small	4
densenet201	3	swin_tiny	3
efficientnet_b0	3	tf_efficientnet	2
efficientnet_b2	3	vgg16	3
efficientnet_b3	3	vit_b32	2
efficientnet_b4	2	vit_base	9
inception_v3	3	vit_large	2
mixer_b16	2	vit_small	4
mnasnet	3	vit_tiny	2
mobilenet_v3_large	4	wide_resnet50_2	3
mobilenet_v3_small	3		

多变体结构。模型清单包含 48 组、132 个变体，主支持为 35 个多变体组、119 个变体。VGG16-BN 是主支持之外的单成员组。规范代表取每组按字典序排列的首个变体。单阶段评估为 119 次。完整 132 候选池的 RankMe、SSR‡ 诊断遗憾分别为 0.152、0.082，有各自的 oracle，与主支持比较分开报告。

来源与 LP 敏感性。每个 torchvision VGG 模型均有三种提取设置的目标及 STL-10 缓存：25088 维展平特征、4096 维双重变换、4096 维一次官方变换。清单记录路径、时间戳、缓存/权重/脚本哈希、LP 划分、预测和求解器版本。独立检查验证全部 36 个缓存，并复现两种 4096 维设置下全部 20 个 LP 单元的预测。这两种设置及测试的 scikit-learn 版本（1.6.1 和 1.2.2）给出相同的 22 单元 RankMe/SSR‡ 遗憾，尽管个别 VGG 的 LP 准确率可能不同。该敏感性测试不证明辅助指标或未测试候选的协议等价。

版本来源与更正。 早期版本使用 torchvision VGG 的 25088 维展平特征，却描述为 4096 维倒数层特征。当前模型清单替换两个 VGG 模型的十个目标行，另外 650 行保持不变。22 单元的 SSR 减 RankMe 差值从 -0.1043 变为 -0.0645，且 MV RankMe 优于随机。早期的 MV 差于随机、无充分支持的 CNN-only/Transformer-only 效应、普遍同族优势等主张不受支持。有效秩归一化、官方有标签 DiSCO、目标分离参考比较和候选支持集均以当前协议为准。原始受影响缓存的来源不完整；新清单记录替换数据，而非重建该历史。

C SSL/多模态池

额外数据集来源。除附录 B、D、E 引用的数据集外，SSL 模型清单还包含 MNIST [22]、USPS [17]、GTSRB [37]、Semeion [34] 和 Beans [27]。CIFAR-100-coarse 使用 CIFAR-100 的超类标签 [21]。Rendered-SST2 是 CLIP [33] 使用的 Stanford Sentiment Treebank [36] 图像渲染版本。Beans 和 Semeion 引用原始数据发布记录，而不假定存在独立论文。

十一个生物医学任务使用 MedMNIST [43]：PathMNIST（结直肠组织学图像 [18]）、DermaMNIST（HAM10000/ISIC [8, 39]）、OCTMNIST 和 PneumoniaMNIST [19]、RetinaMNIST（DeepDRiD [23]）、BreastMNIST [2]、BloodMNIST [1]、TissueMNIST [25]，以及 OrganAMNIST/OrganCMNIST/OrganSMNIST（LiTS 图像及器官标注 [3, 42]）。这些引用区分了标准化任务与底层图像来源；我们不声称采集了这些图像。

设置。我们从 8 个 SSL/多模态编码器提取倒数第二层特征：ResNet-50/101、MoCo-v3-R50、ConvNeXt-B、ViT-B/16、CLIP-ViT-L/14、DINOv2-ViT-B/14 和 DINO-ViT-S/16。特征维度 $d \in \{384, 768, 1024, 2048\}$，不含 VGG 类架构。评估使用覆盖 VTAB、MedMNIST 变体和标准迁移基准的 29 个下游任务，LP 真值采用与 MV 相同的 80/20 逻辑回归协议。

可用支持与范围。留存的 SSL 表包含 $8 \times 29 = 232$ 个可能单元中的 209 个。23 个任务各有八个候选，FGVC-Aircraft 有四个，Flowers-102、Food-101、Oxford-Pets 和 Rendered-SST2 各有五个，Semeion 只有一个。Oracle 在可用候选内计算，因此 Semeion 的选择遗憾必为零。官方 DiSCO 与同一组 209 个 LP 单元匹配。这些历史诊断不是完整矩形基准，不纳入 22 单元主比较。历史 SSR 脚本指定 ImageNet 参考特征，并设有逐模型 CIFAR-10 回退路径，但没有保留逐次运行的参考清单。因此，其 SSR 列不被视为已验证的目标分离 STL-10 评估，也不用于支撑主校正结论。

诊断限制。SSL 支持不完整且缺少逐次运行的参考清单，因此不能在主实验的目标分离协议下完整对齐 RankMe/SSR‡ 比较。官方 DiSCO 结果是可用 209 单元上的描述性结果，与主实验零标签比较分开呈现。

有标签比较。官方 PCA-128 DiSCO 在可用的 29 个 SSL 任务上，$G = 6/8$ 的遗憾为 0.045/0.042；完整特征评分为 0.057/0.047，属于不同维度设置。官方分类 DiSCO 使用目标真实标签形成类条件协方差，因此与零标签 SSR‡–RankMe 比较分开报告。

正文表 7 汇总这些有标签结果及 MV、VTAB、EX 的对应结果。

D VTAB 池

数据集来源。除附录 B 中的共同来源，本池使用 Fashion-MNIST [41]、Flowers-102 [30]、Oxford-IIIT Pets [32] 和 STL-10 [7]。`pets` 与 `oxford_pets` 指同一数据集。"VTAB 池"指本文保留的评估池，不表示复现完整的原始 VTAB 套件 [44]。

设置。最终共同模型池包含在八个 VTAB 数据集（CIFAR-10/100、DTD、Fashion-MNIST、Flowers-102、Pets、STL-10、SVHN）上同时拥有完整特征和 LP 值的 24 个 timm 预训练架构。原始清单还列出 ResNet-152，但其八个特征文件只有一个可用，因此我们统一排除，而不让候选集随任务变化。STL-10 特征只作为 SA_k 的参考，并从共同支持目标中排除。

参考协议与固定 k。协议采用未经额外中心化的 SVD 和 RankMe 的奇异值归一化，并排除 STL-10 目标。$k = 20$ 时，以 STL-10 为单参考，在完整 24 架构支持的其余七个任务上遗憾为 0.061。参考敏感性只使用目标与参考分离的比较。我们固定使用 $k = 20$，不按目标标签调参。该最终评估协议下对 k 的敏感性尚未验证。

评估支持。模型清单含 660 个 MV、510 个 EX 和 192 个 VTAB 模型–任务单元，其中 168 个 VTAB 单元对应非参考目标。22 单元汇总使用 MV 多变体支持、全部七个非参考 VTAB 目标及十个 EX 目标。七任务单参考与集成遗憾分别为 0.061/0.055。

多参考稳健性。为实现目标不重叠的评估，当当前目标与参考名称相同，就从预先确定的 STL-10、CIFAR-10、Flowers-102、Pets 集合中删去该参考，并对其余对齐度取中位数。该逐目标留一集成遗憾为 0.055，单独使用 STL-10 为 0.061。考虑到证据仅来自七个任务，且参考侧成本约为 M 倍，我们保留单参考作为默认设置。参考设计仍是开放问题。

E EX 池与阶段 1 比较

数据集来源。FGVC-Aircraft [26] 和 Food-101 [4] 补充了附录 B、D 引用的八个目标数据集；STL-10 不是 EX 目标。

EX 池。EX 包含来自 35 个规范架构的 51 个 ImageNet-1k 监督预训练变体，其中包括 $d = 4096$ 的 VGG-16，$d_{\max}/d_{\min} = 21.3$。十个目标涵盖细粒度识别（FGVC-Aircraft、Flowers-102、Food-101、Oxford-Pets）、纹理/场景（DTD、EuroSAT）、数字/服饰（SVHN、Fashion-MNIST）和通用物体（CIFAR-10/100），特征在完整数据集上提取。Flat-SSR‡ 遗憾为 0.0595，RankMe 为 0.1445。依赖目标标签的官方 DiSCO 在 $G = 6/8$ 时为 $+0.045/+0.049$，不纳入零标签比较。

完整支持的辅助比较见表 5。

谱截断。完整 118 候选辅助支持上，top-256 RankMe 遗憾为 0.134，介于完整谱 RankMe 的 0.144 和 SSR‡ 的 0.098 之间。相应的截断分数 →RankMe 两阶段遗憾为 0.136，SSR‡ →RankMe 为 0.102。这些是特定设置中的观察，不证明截断本质上不适用。

F 消融与负结果

信息预算。DiSCO 使用目标标签，$\mathrm{SSR}^{\ddagger}$ 不使用。宽度范围本身不是在二者间选择的已验证标准。默认关系分数将权重固定为一，不进行跨池调参。

校正的代数形式。MV 上，$-\alpha \log \mathrm{SA}_k$ 在测试点 $\alpha = 0.5, 1, 2$ 的遗憾分别为 0.098、0.098、0.093。三个离散点不证明整个连续区间稳定。完整 118 候选辅助支持上，加法变体 $g(s) = 1 - s$、$\beta = 1$ 的遗憾为 0.117。其实现分数 $(\log r_{\mathrm{eff}} - s)/\log C$ 与家族定义相差任务内常数 $1/\log C$，因此排序及遗憾一致，但原始分数不同。反向控制 $-\log(1 - \mathrm{SA}_k)$ 为 0.388。保持 $\alpha = 1$ 而不利用目标表现调参，这些对照仅展示关系项形式的敏感性。

逐任务选择。选择和 oracle 见表 4。RankMe 在四任务选择 ResNeXt，在 SVHN 选择 Inception。$\mathrm{SSR}^{\ddagger}$ 在四个配对任务比较中更优，但在 SVHN 更差。

UID 归一化分数。定义 $R_{\mathrm{UID}} = \log r_{\mathrm{eff}}/(\mathrm{UID} \log C)$，其中 UID 为保留的 TwoNN 内在维度估计 [11]。该分数将有效秩的对数除以 UID 及 $\log C$，而非直接按 UID 值对候选排序。完整 118 候选辅助支持上，单阶段 R_{UID} 遗憾为 0.364，$\mathrm{SSR}^{\ddagger}$ 为 0.098。但 $R_{\mathrm{UID}} \rightarrow$RankMe 在该支持及主实验 119 候选上均为 0.058：虽然一个非规范代表的辅助单元缺失，全部 35 个阶段 1 规范代表分数均可用。因此，单阶段排名较差不一定意味着第一阶段筛选较差。这项五任务事后比较优于所评估的 $\mathrm{SSR}^{\ddagger}$ 流程，但不构成通用 UID 选择规则。

窄池适用范围。现有证据不能仅根据 CNN/Transformer 归属确定普遍更优的分数。关于同质子池的主张需要匹配的候选与任务支持。

同族排序与任务缩放。35×5 个架构–任务组中，两组的 LP 为常数；剩余 173 组的平均组内 Spearman 相关为 RankMe 0.527、$\mathrm{SSR}^{\ddagger}$ 0.519。这只是描述性结果，不是显著优越性主张。固定任务内，包括 $1/\log C(T)$ 在内的公共正比例缩放不改变候选排序。我们聚合逐任务遗憾而非原始分数。

G 实验环境与计算资源核算

NPU 特征提取。MV/EX DiSCO 特征提取启动器使用 PyTorch 与 `torch_npu`/Ascend，四个 NPU 设备（0–3），每设备一个模型分片，批大小 64，推理模式与 float32 缓存。这并不能确定每份历史缓存的硬件来源。

缓存特征分析。DiSCO、线性探针、参考比较与 bootstrap 使用 CPU 上的 NumPy/SciPy/scikit-learn 程序。MV/EX DiSCO 启动器使用 16 个工作进程；缓存避免为不同分数重复编码器推理。

VGG 提取环境。两个 VGG 模型使用 NVIDIA L20（约 46 GB）、批大小 64、float32 缓存、PyTorch 2.5.1+cu124、torchvision 0.20.1、Python 3.11.11、NumPy 1.26.4、SciPy 1.15.3 和 scikit-learn 1.6.1。主机暴露 16 个 CPU 线程、约 123 GiB 内存，评分限制为八线程。LP 使用 seed=0 分层 800/200 划分、仅在训练集拟合 StandardScaler、$C = 1$、lbfgs、max_iter=1000。隔离的 sklearn 1.2.2 对照改变部分 VGG LP，但不改变主实验遗憾。缓存和脚本哈希、实际生成时间均已记录。

报告范围。第 6 节统计候选–任务评估次数，而非运行时间、能耗或硬件加速比；参考初始化另计。历史硬件、软件和运行时间记录不完整，无法完整报告计算资源，检查清单中该项仍回答“否”。